

高等数值分析

张鑫航

国防科技大学

版本：1.0

更新：2024 年 6 月 20 日



判断 $10 \times 3'$

大题 6

目录

1	绪论	5
1.1	误差的来源和分类	5
1.2	误差度量	5
1.3	误差分析方法与原则	8
2	数值逼近	8
2.1	插值法	8
2.2	Lagrange 插值	9
2.3	Newton 插值	12
2.3.1	差分与等距节点插值公式	13
2.4	Hermite 插值	14
2.5	分段低次插值	16
2.5.1	分段线性插值	16
2.5.2	分段 Hermite 插值	17
2.6	三次样条插值	17
3	函数逼近	18
3.1	最佳一致逼近	18
3.1.1	Chebyshev 多项式	19
3.2	最佳平方逼近	22
3.3	正交多项式	23
3.4	最小二乘法	25
4	数值积分与数值微分	26
4.1	数值积分基本概念	26

4.2	Newton-Cotes 求积公式	28
4.2.1	复化求积法及其收敛性	29
4.3	Romberg 算法	30
4.4	高斯 (Gauss) 公式	32
4.4.1	固定部分节点的高斯型求积公式	35
4.5	二重积分计算方法	36
4.5.1	复合求积公式	36
4.6	数值微分	37
4.6.1	机械求导公式	37
5	微分方程数值解的基本概念 (没有大题)	38
5.1	微分方程数值解的基本概念	38
5.2	Euler 方法	39
5.3	Runge-Kutta 方法	40
5.4	单步法的收敛性与稳定性	43
5.5	线性多步法 (1)	44
5.6	方程组与刚性问题	45
5.7	边值问题的解法	46
6	方程求根	47
6.1	非线性方程求根的基本概念	47
6.2	跟的搜索与二分法	47
6.3	不动点迭代法	48
6.4	Newton 迭代法	51
6.5	非线性方程组的解法	53
7	解线性方程组的直接法	56

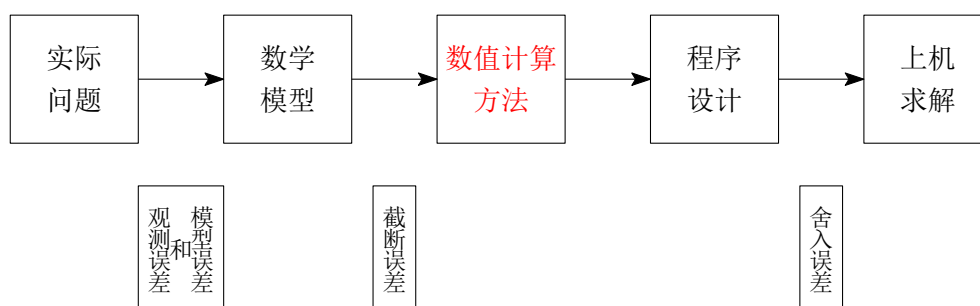
7.1	Gauss 消元法	58
7.2	直接三角分解法	60
7.3	大型带状方程组的求解	63
7.4	向量和矩阵范数	63
7.5	条件数与病态矩阵	65
8	解线性方程组的迭代法	66
8.1	迭代法的构造	66
8.1.1	Jacobi 迭代法	69
8.1.2	Gauss-Seidel 迭代法	69
8.1.3	SOR	70
8.2	梯度法	72
8.3	最速下降法	72
8.3.1	共轭方向法	72
9	矩阵的特征值和特征向量的计算	74
9.1	特征值理论	74
9.2	幂法	74
9.2.1	幂法	75
9.2.2	改进幂法	75
10	2023 春考试题目	76

1 绪论

1.1 误差的来源和分类

定义 1.1 (舍入误差) 由于计算机字长的有限性, 对相关数据进行存储表示时便产生舍入误差。

定义 1.2 (截断误差) 计算机必须在有限的时间内得到运行结果, 于是无穷的运算过程必须截断为有限过程, 由此产生截断误差。



1.2 误差度量

定义 1.3 (误差) 设 x 为精确值 (准确值), x^* 是 x 的一个近似值, 称 $e^* = x^* - x$ 为近似 x 的绝对误差或误差。

定义 1.4 (误差限) 如果精确值 x 与近似值 x^* 的误差的绝对值不超过某正数 ε , 即

$$|e| = |x^* - x| < \varepsilon$$

称 ε 为绝对误差限或误差限。

定义 1.5 (相对误差) 设 x 为精确值 (准确值), x^* 是 x 的一个近似值, 称 $r = \frac{e^*}{x^*} = \frac{x^* - x}{x^*}$ 为近似 x 的相对误差。

定义 1.6 (相对误差限) 如果有正数 ε_r , 使得 $r = \left| \frac{e^*}{x^*} \right| < \varepsilon_r$, 则称 ε_r 为 x 的相对误差限。

定义 1.7 (有效数字) 当 x 的误差限为 某一位 的半个单位, 则 这一位 到第一个非零位的位数称为 x 的有效位数。若有效数字共有 n 个, 则称 x 有 n 位有效数字, 或者说 x 精确到 n 位。

或者说对于用标准形式表示的近似值 x^*

$$x^* = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_n \times 10^{-(n-1)})$$
$$a_i \in \{1, 2, \cdots, 9\}, i = 1, 2, \cdots, n-1$$

有

$$|x^* - x| < \frac{1}{2} \times 10^{m-n+1}$$

定理 1.1 对于用标准形式表示的近似值 x^*

$$x^* = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_n \times 10^{-(n-1)})$$
$$a_i \in \{1, 2, \cdots, 9\}, i = 1, 2, \cdots, n-1$$

若 x^* 具有 n 位有效数字, 则其相对误差限为

$$r \leq \frac{1}{2a_1} \times 10^{-(n-1)}$$

反之, 若 x^* 的相对误差限 $r \leq \frac{1}{2(a_1 + 1)} \times 10^{-(n-1)}$, 则 x^* 至少具有 n 位有效数字。

证明. 对于 x^* 有

$$a_1 \times 10^m \leq |x^*| \leq (a_1 + 1) \times 10^m$$

则, 相对误差限 r

$$r = \frac{|x^* - x|}{|x^*|} \leq \frac{\frac{1}{2} \times 10^{m-n+1}}{a_1 \times 10^m} = \frac{1}{2a_1} \times 10^{-(n-1)}$$

反之, 若 $r \leq \frac{1}{2(a_1 + 1)} \times 10^{-(n-1)}$, 有

$$|x^* - x| = r|x^*| < \frac{1}{2(a_1 + 1)} \times 10^{-(n-1)} \times (a_1 + 1) \times 10^m = \frac{1}{2} \times 10^{m-n+1}$$

则 x^* 至少具有 n 位有效数字。证毕!

定理 1.2 四舍五入所得皆为有效数字。

证明. 若将精确值 x 表示为

$$x = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_n \times 10^{-(n-1)} + a_{n+1} \times 10^{-n} + \cdots)$$

将 x 四舍五入到第 n 位得到 x^*

$$x^* = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a'_n \times 10^{-(n-1)})$$

对于四舍五入到第 n 位得到的 x^* , 有以下两种情况:

1. $a'_n - a_n = 0$, $a_{n+1} < 5$ (靠近原点)

$$|(a'_n - a_n) - a_{n-1} \times 10^{-1}| < \frac{1}{2}$$

2. $a'_n - a_n = 1$, $5 \leq a_{n+1} < 10$ (远离原点)

$$|(a'_n - a_n) - a_{n-1} \times 10^{-1}| < \frac{1}{2}$$

那么 $|x^* - x|$ 有

$$\begin{aligned} |x^* - x| &= 10^{m-n+1} \times |(a_n - a'_n) + a_{n-1} \times 10^{-1}| \\ &< \frac{1}{2} \times 10^{m-n+1} \end{aligned}$$

证毕!

注 误差的传播: 记 x^* 和 y^* 分别为 x 和 y 的近似值, 则初始误差与计算结果中产生的误差有下列关系

$$\begin{aligned} \varepsilon_{x^* \pm y^*} &= \varepsilon_{x^*} + \varepsilon_{y^*}, \quad \varepsilon_{r_{x^* \pm y^*}} = \frac{\varepsilon_{x^*} + \varepsilon_{y^*}}{x^* \pm y^*} \\ \varepsilon_{x^* \cdot y^*} &= x^* \varepsilon_{y^*} + y^* \varepsilon_{x^*}, \quad \varepsilon_{r_{x^* \cdot y^*}} = \frac{x^* \varepsilon_{y^*} + y^* \varepsilon_{x^*}}{x^* \cdot y^*} \\ \varepsilon_{\frac{x^*}{y^*}} &\approx \frac{x^* \varepsilon_{y^*} + y^* \varepsilon_{x^*}}{y^{*2}}, \quad \varepsilon_{r_{\frac{x^*}{y^*}}} \approx \frac{x^* \varepsilon_{y^*} + y^* \varepsilon_{x^*}}{x^* \cdot y^*} \\ \varepsilon(f(\mathbf{x}^*)) &\approx \sum_{i=1}^n \left| \frac{\partial f(\mathbf{x}^*)}{\partial x_i} \right| \varepsilon(x_i^*) \\ \varepsilon_r(f(\mathbf{x}^*)) &\approx \sum_{i=1}^n \left| \frac{\partial f(\mathbf{x}^*)}{\partial x_i} \right| \frac{\varepsilon(x_i^*)}{f(\mathbf{x}^*)} \end{aligned}$$

例 1.1 设 $V = \frac{4\pi R^3}{3}$, 当半径 R 有误差时, 求球体积 V 的相对误差与 R 的相对误差的关系。★★★★☆

$$e_r[V] = \frac{e[V]}{V} = \frac{4\pi R^2 \cdot e[R]}{\frac{4\pi R^3}{3}} = 3 \frac{e[R]}{R} = 3e_r R$$

例 1.2 设 $x > 0$, x 的相对误差为 δ , 求 $\ln x$ 的误差。★★★★☆

$$\ln x - \ln x^* = \ln \frac{x}{x^*} = \ln \frac{x - x^* + x^*}{x^*} = \ln(\delta + 1) \approx \delta$$

或者

$$e(\ln x^*) \approx \frac{e(x^*)}{x^*} = e_r(x^*) = \delta$$

例 1.3 设 x 的相对误差为 2%, 求 x^n 的相对误差。★★★★☆

$$e_r(x^n) \approx n \frac{x^{*(n-1)} e(x^*)}{x^{*(n)}} = n e_r(x^*) = 0.02n$$

1.3 误差分析方法与原则

定义 1.8 (病态问题) 对于一个数值问题，若输入数据的微小扰动（即误差）会引起输出数据（即问题解）相对误差很大，这就是**病态问题**。

定义 1.9 (数值稳定性) 一个算法如果原始数据有扰动（即误差），二计算过程中舍入误差不增长，则称此算法是数值稳定的；否则，若误差增长则称算法数值不稳定。

注 数值运算中误差分析的方法与原则

- 避免除数的绝对值远远小于被除数
- 避免两相近数相减
- 防止大数“吃掉”小数
- 注意简化计算步骤，减少运算次数

2 数值逼近

2.1 插值法

定义 2.1 (插值函数) 已知函数 $y = f(x)$ 在互异节点 $\{x_i\}_{i=0}^n \subset [a, b]$ 处的函数值 $\{y_i = f(x_i)\}_{i=0}^n$ ，若存在简单函数 $p(x)$ ，使得

$$p(x_i) = y_i, (i = 0, 1, \dots, n) \quad (2-1)$$

成立，则称 $p(x)$ 是 $f(x)$ 关于节点 $\{x_i\}_{i=0}^n$ 的一个插值函数。 $\{x_i\}_{i=0}^n$ ——插值节点， $[a, b]$ ——插值区间， $f(x)$ ——被插值函数。

注 用 $p(z)$ 的值作为 $f(z)$ 的近似值，当元在节点形成的区间上时，称该方法为内插法；当元不在节点形成的区间上但在插值区间上，则称该方法为外插法。

注 当插值函数 $p(z)$ 为多项式时，称 $p(x)$ 是 $f(x)$ 的一个插值多项式。插值余项 $R(x) \stackrel{\text{def}}{=} f(x) - p(x)$ ，插值余项又称为截断误差。

定理 2.1 (插值多项式的存在惟一性定理) 满足插值条件 (2-1) 的不超过 n 次的插值多项式 $p(x)$ 是存在唯一的。

推论 若 $f(x)$ 是不超过 n 次的多项式，则它的关于 $n+1$ 个互异节点 $\{x_i\}_{i=0}^n$ 的不超过 n 次的插值多项式 $p(x)$ 与被插值函数 $f(x)$ 恒等，即有

$$p(x) \equiv f(x)$$

注 误差的估计：

- 若被插值函数 $f(x) \in C^{n+1}[a, b]$, 则有插值误差估计式

$$|R_n(x)| \leq \frac{M_{n+1}}{(n+1)!} |\omega_{n+1}(x)|$$

- 若仅需估计某一点 \bar{x}^* 处的插值误差, 则利用

$$|R(\bar{x})| \leq \frac{M_{n+1}}{(n+1)!} |\omega_{n+1}(\bar{x})|, \bar{x} \in [a, b]$$

- 若要估计在整个插值区间上的误差, 用

$$|R(\bar{x})| \leq \frac{M_{n+1}}{(n+1)!} |\omega_{n+1}(x)|, \forall x \in [a, b]$$

其中, M_{n+1} 和 $\max_{x \in [a, b]} |\omega_{n+1}(x)|$ 用微积分中求极值的方法进行。

2.2 Lagrange 插值

设 $p(x)$ 是形如 $p(x) = a_0 + a_1x + a_2x^2 + \cdots + a_nx^n$, 根据 $n+1$ 个互异节点 $\{x_i\}_{i=0}^n$, 得到

$$\begin{cases} a_0 + a_1x_0 + \cdots + a_nx_0^n = y_0, \\ a_0 + a_1x_1 + \cdots + a_nx_1^n = y_1, \\ \vdots \\ a_0 + a_1x_n + \cdots + a_nx_n^n = y_n. \end{cases}$$

因为

$$V_n(x_0, x_1, \cdots, x_n) = \begin{vmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{vmatrix} \neq 0$$

所以方程存在唯一一组解 a_0, a_1, \cdots, a_n , 故而拉格朗日插值多项式也存在且唯一。

$$p_n(x) = L_n(x) = \sum_{i=0}^n f(x_i) l_i(x)$$

拉格朗日插值多项式需要满足 $p_n(x_i) = f(x_i)$, 故而 n 次多项式 $l_i(x)$ 需要满足

$$l_i(x_j) = \begin{cases} 1, & j = i \\ 0, & j \neq i \end{cases}$$

可以将拉格朗日插值基函数 $\{l_i(x)\}_{i=0}^n$ 的定义如下:

$$l_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j} = \frac{\omega_{n+1}(x)}{(x - x_i)\omega'_{n+1}(x_i)}$$

其中

$$\begin{aligned}\omega_{n+1}(x) &= (x-x_0)(x-x_1)\cdots(x-x_n) \\ \omega'_{n+1}(x_k) &= (x_k-x_0)\cdots(x_k-x_{k-1})(x_k-x_{k+1})\cdots(x_k-x_n)\end{aligned}$$

定理 2.2 (插值余项定理) 设 $f^n(x)$ 在 $[a, b]$ 上连续, $f^{n+1}(x)$ 在 (a, b) 上存在, 节点 $a \leq x_0 < x_1 < \cdots < x_n \leq b$, $L_n(x)$ 是满足条件 $p_n(x_i) = f(x_i)$ 的多项式, 则对任何 $x \in [a, b]$, 插值余项

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x)$$

这里, $\xi \in (a, b)$ 且依赖于 x 。

证明. 由给定条件知, $R_n(x)$ 在 $\{x_i\}_{i=0}^n$ 上为 0, 即

$$R_n(x_i) = 0$$

于是

$$R_n(x) = K(x) \omega_{n+1}(x)$$

其中 $K(x)$ 是与 x 有关的待定系数。现在把 x 看成 $[a, b]$ 上的一个固定点, 做函数

$$\phi(t) = f(t) - L_n(t) - K(x) \omega_{n+1}(t)$$

容易知道 $\phi(t)$ 在点 x, x_0, \cdots, x_n 这 $n+2$ 个点上满足 $\phi(t) = 0$, 反复利用 Rolle 定理, 知道

$$\phi^{(n+1)}(\xi) = f^{(n+1)}(\xi) - (n+1)!K(x) = 0$$

于是

$$K(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}$$

证毕!

评论 ξ 在 (a, b) 内的具体位置通常不可能给出, 如果可以求出 $\max_{a \leq x \leq b} |f^{(n+1)}(x)| = M_{n+1}$, 那么插值多项式 $L_n(x)$ 逼近 $f(x)$ 的截断误差是

$$|R_n(x)| \leq \frac{M_{n+1}}{(n+1)!} |\omega_{n+1}(x)|$$

推论 若 $f(x)$ 是不超过 n 次的多项式, 则它的关于 $n+1$ 个互异节点 $\{x_i\}_{i=0}^n$ n 次的拉格朗日插值多项式 $L_n(x)$ 有

$$R_n(x) = f(x) - L_n(x) = 0$$

即

$$f(x) = L_n(x) = \sum_{i=0}^n f(x_i) l_i(x)$$

例 2.1 证明 $\sum_{i=0}^5 (x - x_i)^2 l_i(x) = 0$, 其中 $l_i(x)$ 是关于 $\{x_0, x_1, \dots, x_5\}$ 的插值基函数。

★★★★★

证明.

$$\begin{aligned} \sum_{i=0}^5 (x - x_i)^2 l_i(x) &= x^2 \sum_{i=0}^5 1 \cdot l_i(x) - 2x \sum_{i=0}^5 x_i \cdot l_i(x) + \sum_{i=0}^5 x_i^2 \cdot l_i(x) \\ &= x^2 - 2x \cdot x + x^2 = 0 \end{aligned}$$

证毕!

例 2.2 对一条直线采样 10 个点进行 Lagrange 插值, 所得插值多项式是 [1] 次的。

注 Aitken 逐次线性插值法:

用 Lagrange 插值多项式 $L_n(x)$ 计算函数近似值时, 如需增加插值节点, 那么原来算出来的数据均不能利用, 必须重新计算。为克服这个缺点通常可用逐次线性插值方法得到高次插值。

两个 k 次插值多项式可通过线性插值得到 $k+1$ 次插值多项式

$$I_{0,1,\dots,k,l}(x) = I_{0,1,\dots,k}(x) + \frac{I_{0,1,\dots,k-1,l}(x) - I_{0,1,\dots,k}(x)}{x_l - x_k} (x - x_k) \quad (2-2)$$

这是关于节点 $\{x_0, \dots, x_k, x_l\}$ 的插值多项式。显然

- 对于 $i = 0, 1, \dots, k-1$

$$I_{0,1,\dots,k,l}(x_i) = I_{0,1,\dots,k}(x_i) = f(x_i)$$

- 对于 x_k

$$I_{0,1,\dots,k,l}(x_k) = I_{0,1,\dots,k}(x_k) = f(x_k)$$

- 对于 x_l

$$I_{0,1,\dots,k,l}(x_l) = I_{0,1,\dots,k}(x_l) + \frac{f(x_l) - I_{0,1,\dots,k}(x_l)}{x_l - x_k} (x_l - x_k) = f(x_l)$$

这证明了 (2-2) 满足插值条件。

当 $k=0$ 时为线性插值, 当 $k=1$ 时插值节点为 x_0, x_1, x_l , 插值多项式为

$$I_{0,1,l}(x) = I_{0,1}(x) + \frac{I_{0,l}(x) - I_{0,1}(x)}{x_l - x_1} (x - x_1)$$

x_0	$f(x_0)$					$x - x_0$
x_1	$f(x_1)$	$I_{0,1}$				$x - x_1$
x_2	$f(x_2)$	$I_{0,2}$	$I_{0,1,2}$			$x - x_2$
x_3	$f(x_3)$	$I_{0,3}$	$I_{0,1,3}$	$I_{0,1,2,3}$		$x - x_3$
x_4	$f(x_4)$	$I_{0,4}$	$I_{0,1,4}$	$I_{0,1,2,4}$	$I_{0,1,2,3,4}$	$x - x_4$

2.3 Newton 插值

$$p_n(x) = N_n(x) = \sum_{i=0}^n f[x_0, x_1, \dots, x_i] \omega_i(x)$$

其中零阶插商

$$f[x_0] = f(x_0), \omega_0(x) \equiv 1, \omega_i(x) = \prod_{k=0}^{i-1} (x - x_k)$$

定义 2.2 (差商) 称 $f[x_0, x_k] = \frac{f(x_k) - f(x_0)}{x_k - x_0}$ 为函数 $f(x)$ 关于 x_0, x_k 的一阶差商, 称

$$f[x_0, x_l, x_k] = \frac{f[x_0, x_k] - f[x_0, x_l]}{x_k - x_l}$$

为 $f(x)$ 关于 x_0, x_k, x_l 的二阶差商。一般的称

$$f[x_0, x_1, \dots, x_m] = \frac{f[x_0, x_1, \dots, x_{k-2}, x_m] - f[x_0, x_1, \dots, x_{k-2}, x_{k-1}]}{x_m - x_{k-1}}$$

为 $f(x)$ 的 k 阶差商。

注 插值误差: 把 x 当作 $[a, b]$ 一点, 可得

$$\begin{aligned} f(x) &= f(x_0) + f[x, x_0](x - x_0) \\ f(x) &= f(x_0) + f[x_0, x_1](x - x_0) + f[x, x_0, x_1](x - x_0)(x - x_1) \\ &\quad \dots \\ f(x) &= f(x_0) + f[x_0, x_1](x - x_0) \\ &\quad + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \dots \\ &\quad + f[x_0, \dots, x_n](x - x_0) \dots (x - x_{n-1}) \\ &\quad + f[x, x_0, \dots, x_n] \prod_{i=0}^n (x - x_i) \rightarrow \text{插值误差 or 余项 } R_n(x) \end{aligned}$$

由上, 得

$$f(x) = N_n(x) + f[x, x_0, \dots, x_n] \prod_{i=0}^n (x - x_i)$$

和拉格朗日插值对比

$$f(x) = L_n(x) + \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x)$$

注 差商有如下性质：

1. k 阶差商可表示为函数值 $f(x_0), \dots, f(x_k)$ 的线性组合，即

$$f[x_0, x_1, \dots, x_k] = \sum_{j=0}^k \frac{f(x_j)}{(x_j - x_0) \cdots (x_j - x_{j+1})(x_j - x_{j+1}) \cdots (x_j - x_k)}.$$

这个性质也表明差商与节点的排列顺序无关（插值的对称性）。

2. 差商与导数的关系

$$f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!}, \quad \xi \in [a, b]. \quad (2-3)$$

证明.

$$f(x) = N_{n-1}(x) + f[x, x_0, \dots, x_{n-1}] \omega_n(x)$$

记 $R(x) = f(x) - N_{n-1}(x) = f[x, x_0, \dots, x_{n-1}] \omega_n(x)$ ，固定 x ，令

$$g(t) = f(t) - N_{n-1}(x) - f[x, x_0, \dots, x_{n-1}] \omega_n(t)$$

对于 $\{x, x_0, \dots, x_{n-1}\}$ 有

$$g(x) = g(x_0) = \cdots = g(x_{n-1}) = 0$$

反复利用 Rolle 定理，得到

$$g^{(n)}(\xi) = f^{(n)}(\xi) - f[x, x_0, \dots, x_{n-1}] n! = 0$$

即（这一步将 x_n 带入 x ，并利用插值的对称性）

$$f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!}, \quad \xi \in [a, b].$$

证毕！

x_k	$f(x_k)$	一阶差商	二阶差商	三阶差商	四阶差商
x_0	$f(x_0)$				
x_1	$f(x_1)$	$f[x_0, x_1]$			
x_2	$f(x_2)$	$f[x_1, x_2]$	$f[x_0, x_1, x_2]$		
x_3	$f(x_3)$	$f[x_2, x_3]$	$f[x_1, x_2, x_3]$	$f[x_0, x_1, x_2, x_3]$	
x_4	$f(x_4)$	$f[x_3, x_4]$	$f[x_2, x_3, x_4]$	$f[x_1, x_2, x_3, x_4]$	$f[x_0, x_1, x_2, x_3, x_4]$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots

2.3.1 差分与等距节点插值公式

设等式 $y = f(x)$ 在等距节点 $x_k = x_0 + kh$ ($k = 0, 1, \dots, n$) 上的值 $f_k = f(x_k)$ 为已知，这里 h 为常数，称为步长。

定义 2.3 (偏差)

$$\begin{aligned}\Delta f_k &= f_{k+1} - f_k \\ \nabla f_k &= f_k - f_{k-1} \\ \delta f_k &= f(x_k + h/2) - f(x_k - h/2) = f_{k+\frac{1}{2}} - f_{k-\frac{1}{2}}\end{aligned}$$

分别为向前差分、向后差分以及中心差分。

推论 (差商与差分的关系★★★★★)

$$\begin{aligned}f[x_k, x_{k+1}, \dots, x_{k+m}] &= \frac{1}{m!} \frac{1}{h^m} \Delta^m f_k, \quad (m = 1, 2, \dots, n) \\ f[x_k, x_{k-1}, \dots, x_{k-m}] &= \frac{1}{m!} \frac{1}{h^m} \Delta^m f_k\end{aligned}$$

同时利用 (2-3) 可以得到

$$\Delta^n f_k = h^n f^{(n)}(\xi), \quad \xi \in (x_k, x_{k+n})$$

2.4 Hermite 插值

不少实际问题不但要求在节点上函数值相等, 而且还要求它的导数值相等, 甚至要求高阶导数值也相等. 满足这种要求的插值多项式就是 Hermite 插值多项式.

已知节点 $\{x_j\}_{j=0}^n$, 满足

$$H(x_j) = y_j, \quad H'(x_j) = m_j = f'(x_j)$$

可以确定 $2n+1$ 次的多项式

$$H_{2n+1}(x) = a_0 + a_1x + \dots + a_{2n+1}x^{2n+1} \quad (2-4)$$

插值误差

$$R_n(x) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \omega_{n+1}^2(x)$$

用基函数表示 (2-4) 为

$$H_{2n+1}(x) = \sum_{i=0}^n [\alpha_i(x)f_i + \beta_i(x)f'_i]$$

其中 $\alpha_i(x)$ 和 $\beta_i(x)$ 均为 $2n+1$ 次多项式, 且满足

$$\begin{cases} \alpha_i(x_k) = \delta_{ik}, & \alpha'_i(x_k) = 0 \\ \beta_i(x_k) = 0, & \beta'_i(x_k) = \delta_{ik} \end{cases} \quad (2-5)$$

注 下面的问题就是求满足条件 (2-5) 的基函数 α_i 和 $\beta_i(x)$ 。

- 先求 $\alpha_i(x)$, 可利用 Lagrange 插值基函数 $l_i(x)$, 令 (1. $2n+1$ 次多项式, 2. 在 $x_j \neq x_i$ 处为 2 重零点)

$$\alpha_i(x) = [a(x - x_i) + b]l_i^2(x)$$

其中 $l_i(x) = \prod_{j=0, j \neq i}^n \frac{x - x_j}{x_i - x_j}$. 由 $\alpha_i(x_i) = 1$, 知 $b = 1$; 由 $\alpha_i'(x_i) = 0$ 知

$$al_i^2(x_i) + 2[a(x_i - x_i) + 1]l_i(x_i)l_i'(x_i) = 0$$

$$a = -2l_i'(x_i)$$

$$(\ln l_i(x_i))' = \frac{l_i'(x_i)}{l_i(x_i)} = \sum_{\substack{j=0 \\ j \neq i}}^n \frac{1}{(x_i - x_j)}$$

$$a = -2 \sum_{\substack{j=0 \\ j \neq i}}^n \frac{1}{(x_i - x_j)}$$

故有

$$\alpha_i(x) = \left[1 - 2(x - x_i) \sum_{\substack{j=0 \\ j \neq i}}^n \frac{1}{(x_i - x_j)} \right] l_i^2(x)$$

- 再求 $\beta_i(x)$, 同理设 $\beta_i(x) = [a(x - x_i) + b]l_i^2(x)$ (1. $2n+1$ 次多项式, 2. 在 $x_j \neq x_i$ 处为 2 重零点)。由 $\beta_i(x_i) = 0$, 知 $b = 0$; 由 $\beta_i'(x_i) = 1$ 知,

$$al_i^2(x_i) + 2[a(x_i - x_i) + 0]l_i(x_i)l_i'(x_i) = 1$$

$$a = 1$$

故有

$$\beta_i(x) = (x - x_i)l_i^2(x)$$

综上,

$$\alpha_i(x) = \left[1 - 2(x - x_i) \sum_{j=0, j \neq i}^n \frac{1}{(x_i - x_j)} \right] l_i^2(x)$$

$$\beta_i(x) = (x - x_i)l_i^2(x)$$

例 2.3 设 $f(x) = \ln x$, 给定 $f(1) = 0, f(2) = 0.693147, f'(1) = 1, f'(2) = 0.5$, 用三次 Hermite 插值多项式 $H_3(x)$ 计算 $f(1.5)$ 的近似值。★★★★★

请写出 $x = 1$ 处的导数值基函数 $\beta_1(x)$ 和 $x = 2$ 处的函数值基函数 $\alpha_2(x)$

解 $\beta_1(x) = (x - 1) \left[\frac{(x - 2)}{1 - 2} \right]^2, \quad \alpha_2(x) = \left[1 - 2(x - 2) \frac{1}{2 - 1} \right] \left[\frac{(x - 1)}{2 - 1} \right]^2$

例 2.4 求一个次数不高于四次的多项式 $p(x)$, 使它满足 $p(0) = p'(0) = 0, p(1) = p'(1) = 1, p(2) = 1$ 。★★★★★

解 [解法一]: 设 $p(x) = [\alpha_1(x)p(0) + \alpha_2(x)p(1) + \alpha_3(x)p(2) + \beta_1(x)p'(0) + \beta_2(x)p'(1)]$, 满足可以设

	函数值			导数值	
	0	1	2	0	1
$\alpha_1(x)$	1	0	0	0	0
$\alpha_2(x)$	0	1	0	0	0
$\alpha_3(x)$	0	0	1	0	0
$\beta_1(x)$	0	0	0	1	0
$\beta_2(x)$	0	0	0	0	1

$$\alpha_1(x) = (ax + b)(x - 1)^2(x - 2)$$

$$\alpha_2(x) = (ax + b)x^2(x - 2)$$

$$\alpha_3(x) = bx^2(x - 1)^2$$

$$\beta_1(x) = (ax + b)x(x - 1)^2$$

$$\beta_2(x) = (ax + b)x^2(x - 1)$$

上述做法要解多个 2 元方程，虽然每个方程计算量不大。

[解法二]：可以看出关于 $x = 0$ 为二重根，设 $p(x) = (ax^2 + bx + c)x^2$ ，可以通过求解 1 个三元方程组

[解法三]：由给定的条件，可确定次数不超过 4 的插值多项式

$$p(x) = f(0) + f[0, 1](x - 0) + f[0, 1, 2](x - 0)(x - 1) + (ax + b)(x - 0)(x - 1)(x - 2)$$

例 2.5 求次数不高于三次的多项式 $p(x)$ ，使得 $p(x_i) = f(x_i) (i = 0, 1, 2)$ 及 $p'(x_1) = f'(x_1)$ 的插值多项式★★★★☆

解 可以设 $p(x)$ 为

$$p(x) = f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + A(x - x_0)(x - x_1)(x - x_2)$$

可以得到

$$A = \frac{f'(x_1) - f[x_0, x_1] - f[x_0, x_1, x_2](x_1 - x_0)}{(x_1 - x_0)(x_1 - x_2)}$$

2.5 分段低次插值

2.5.1 分段线性插值

设已知节点 $a = x_0 < x_1 < \cdots < x_n = b$ 上的函数值为 $f_0, f_1, \cdots, f_n, h_i = x_{i+1} - x_i, h = \max_{0 \leq i \leq n-1} h_i$ ，若一折线 $I_h(x)$ 满足条件：

1. $I_h(x) \in C[a, b]$;
2. $I_h(x_i) = f_i, i = 0, 1, \dots, n$;
3. $I_h(x)$ 在每个小区间 $[x_i, x_{i+1}] (i = 0, 1, \dots, n-1)$ 上为线性函数。

则称 $I_h(x)$ 为分段线性函数，相应的插值为分段线性插值。

$$I_h(x) = \frac{x - x_{i+1}}{x_i - x_{i+1}} f_i + \frac{x - x_i}{x_{i+1} - x_i} f_{i+1}, \quad x \in [x_i, x_{i+1}]$$

例 2.6 分段线性插值可否用基函数表示，若能，请写出基函数；若不能，请说明理由

解 其基函数可表示为

$$l_i(x) = \begin{cases} \frac{x - x_{i-1}}{x_i - x_{i-1}}, & x_{i-1} \leq x \leq x_i \\ \frac{x - x_{i+1}}{x_i - x_{i+1}}, & x_i \leq x \leq x_{i+1} \\ 0, & \text{其他} \end{cases}$$

注 分段线性插值的误差估计

- 若 $f(x) \in C[a, b]$ ，则当 $h \rightarrow 0$ 时 $I_h(x)$ 一致收敛于 $f(x)$ 。
- 若 $f(x) \in C^2[a, b]$ ，则余项 $R(x) = f(x) - I_h(x)$ 有估计式

$$|R(x)| \leq \frac{Mh^2}{8}, \quad M = \max_{a \leq x \leq b} |f''(x)|$$

2.5.2 分段 Hermite 插值

定义 2.4 (分段 Hermite 插值) 设已知节点 $a = x_0 < x_1 < \dots < x_n < b$ 上的函数值为 f_0, f_1, \dots, f_n ，导数值为 f'_0, f'_1, \dots, f'_n 满足插值条件

- $I_h(x) \in C^1[a, b]$
- $I_h(x_i) = f_i, I'_h(x_i) = f'_i$
- $I_h(x)$ 在每个小区间为 3 次多项式

2.6 三次样条插值

定义 2.5 (三次样条插值) 给定 $[a, b]$ 上 $n+1$ 个节点 $a = x_0 < x_1 < \dots < x_n = b$ 和这些点上的函数值 $f(x)_i = y_i, i = 0, 1, \dots, n$ 。若函数 $S(x)$ 满足条件

1. $S(x_i) = f_i$
2. $S(x) \in C^2[a, b]$
3. $S(x)$ 在每个小区间 $[x_i, x_{i+1}]$ 上为三次多项式

则称 $S(x)$ 为 $[a, b]$ 上的三次样条插值函数。

例 2.7 设 $S(x) = \begin{cases} x^3 + x^2, 0 \leq x \leq 1 \\ 2x^3 + ax^2 + bx + c, 1 \leq x \leq 2 \end{cases}$ 是以 0,1,2 为节点的三次样条函数, 则 a, b, c 应取何值?

解

$$\frac{d(x^3 + x^2)}{dx} = 3x^2 + 2x \quad \frac{d^2(x^3 + x^2)}{dx^2} = 6x + 2$$

$$\frac{d(2x^3 + ax^2 + bx + c)}{dx} = 6x^2 + 2ax + b \quad \frac{d^2(2x^3 + ax^2 + bx + c)}{dx^2} = 12x + 2a$$

$$\begin{cases} 2 + a + b + c = 2 \\ 6 + 2a + b = 5 \\ 12 + 2a = 8 \end{cases}$$

解得

$$a = -2, b = 3, c = -1$$

给定 $n+1$ 个插值节点, 确定 $S(x)$ 需要确定 $4n$ (每个区间 4 个参数)。现在有以下

- $S(x_j) = f(x_j)$ (n+1) 个
- $S(x_{j+0}) = f(x_{j-0})$ (n-1) 个
- $S'(x_{j+0}) = f'(x_{j-0})$ (n-1) 个
- $S''(x_{j+0}) = f''(x_{j-0})$ (n-1) 个

少两个条件。

3 函数逼近

3.1 最佳一致逼近

定义 3.1 设 $f \in C[a, b], p_n \in H_n = \text{Span}\{1, x, \dots, x^n\}$, 称

$$\Delta(f, p_n) = \|f - p_n\|_{\infty} = \max_{a \leq x \leq b} |f(x) - p_n(x)|$$

为 p_n 与 f 的偏差

$$E_n = \inf_{p_n \in H_n} \Delta(f, p_n)$$

为 p_n 与 f 的最小偏差

若 $\exists p_n^* \in H_n$, 使 $\Delta(f, p_n^*) = E_n$, 则称 p_n^* 为 f 在 $[a, b]$ 上的最佳一致逼近多项式, 简称最佳逼近多项式。

定义 3.2 (偏差点) 设 $f \in C[a, b], p_n \in H_n$, 若 $\exists x_0 \in [a, b]$ 使得

$$|f(x_0) - p(x_0)| = \Delta(f, p) = \mu$$

则称 x_0 是 p 关于 f 的偏差点。

- 若 $p(x_0) - f(x_0) = \mu$, 则称 x_0 为正偏差点。
- 若 $p(x_0) - f(x_0) = -\mu$, 则称 x_0 为负偏差点。

定理 3.1 设 $p_n^* \in H_n$ 为 $f \in [a, b]$ 的最佳一致逼近多项式, 则 p_n^* 关于 f 的正负偏差点同时存在。

3.1.1 Chebyshev 多项式

定义 3.3 (Chebyshev 多项式) 当权函数 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$, 区间为 $[-1, 1]$ 时, 得到的正交多项式就是 Chebyshev 多项式, 它可以表示为

$$T_n(x) = \cos(n \arccos x), \quad |x| \leq 1$$

推论 递推关系

$$\begin{aligned} T_0(x) &= 1, \quad T_1(x) = x \\ T_{n+1}(x) &= 2xT_n(x) - T_{n-1}(x), \quad (n = 1, 2, \dots, n) \end{aligned}$$

由递推关系式还可以得到 $T_n(x)$ 的最高项系数为 $2^{n-1} (n \geq 1)$

证明. 由和差化积 $\cos(n+1)x - \cos(n-1)x = 2\cos(nx)\cos(x)$ 并令 $x = \arccos x$ 得到

$$\begin{aligned} T_{n+1}(x) - T_{n-1}(x) &= 2xT_n(x) \\ \Rightarrow T_{n+1}(x) &= 2xT_n(x) + T_{n-1}(x) \end{aligned}$$


证毕!

推论 $T_n(x)$ 对零的偏差最小, 可以写成如下定理。

定理 3.2 在区间 $[-1, 1]$ 上所有最高项系数为 1 的一切 n 次多项式中, $\tilde{T}_n(x) = \frac{1}{2^{n-1}}T_n(x)$ 与零的偏差最小, 其偏差为 $\frac{1}{2^{n-1}}$ ★★★★★

注 $T_n(x)$ 的函数及其图形如下:

$$\begin{aligned}
T_0(x) &= 1 \\
T_1(x) &= x \\
T_2(x) &= 2x^2 - 1 \\
T_3(x) &= 4x^3 - 3x \\
T_4(x) &= 8x^4 - 8x^2 + 1 \\
T_5(x) &= 16x^5 - 20x^3 + 5x \\
T_6(x) &= 32x^5 - 48x^4 + 18x^2 - 1 \\
T_7(x) &= 64x^7 - 112x^5 + 56x^3 - 7x \\
T_8(x) &= 128x^8 - 256x^5 + 160x^4 - 32x^2 + 1
\end{aligned}$$



注 性质:

1. 正交性

$$(T_n, T_m) = \begin{cases} 0 & m \neq n \\ \frac{\pi}{2} & m = n \neq 0 \\ \pi & m = n = 0 \end{cases}$$

2. 递推关系 $T_{n+1}(x) = 2xT_n(x) + T_{n-1}(x)$

3. 奇偶性 $T_n(-x) = (-1)^n T_n(x)$

例 3.1 设 $f(x) = x^4$, 在 $[-1, 1]$ 上求 H_3 中的最佳逼近多项式。★★★★☆

解 由定理 3.2 知道

$$\frac{f(x) - p_3^*(x)}{1} = \frac{T_4(x)}{2^{4-1}}$$

其中 $T_4(x) = 8x^4 - 8x^2 + 1$, 故而

$$\begin{aligned}
p_3^*(x) &= f(x) - \frac{T_4(x)}{2^3} \\
&= x^2 - \frac{1}{8}
\end{aligned}$$

例 3.2 求 $f(x) = 2x^3 + x^2 + 2x - 1$ 在 $[-1, 1]$ 上的最佳一致逼近多项式。★★★★☆

解

$$\frac{f(x) - p_2^*(x)}{a_n} = \frac{T_3(x)}{2^{n-1}} \text{ 变成最高次系数为 1 的多项式}$$

故

$$p_2^*(x) = f(x) - \frac{1}{2}T_3(x) = x^2 + \frac{7}{2}x - 1$$

定理 3.3 若 $P(x) \in H_n$ 是 $f(x) \in C[a, b]$ 的最佳逼近多项式, 则 $P(x)$ 同时存在正负偏差点。

定理 3.4 (Chebyshev) $p_n^* \in H_n$ 是 $f \in C[a, b]$ 的最佳逼近多项式的充要条件是: 在 $[a, b]$ 上至少有 $n+2$ 个轮流为正负的偏差点, 即至少有 $n+2$ 个点 $a \leq x_1 \leq x_2 \leq \cdots \leq x_{n+2} \leq b$ 使得

$$p_n^*(x_k) - f(x_k) = (-1)^k \sigma \|f - p_n^*\|_\infty, \sigma = \pm 1, k = 1, 2, \cdots, n+2$$

上述点 $\{x_k\}_1^{n+2}$ 称为切比雪夫交错点。

推论 设 $f \in C[a, b]$, 则在 H_n 中的最佳逼近多项式是唯一的。

推论 若 $f \in C[a, b]$, 则其最佳逼近多项式 $p_n^*(x) \in H_n$ 是 f 的一个拉格朗日多项式。

例 3.3 假定 $f(x) \in C^2[a, b]$, 且 $f''(x)$ 在 (a, b) 内不变号, 求最佳一次逼近多项式 $P_1(x) = a_0 + a_1x$ 。★★★★★

解 根据定理 3.4 可知, 至少有 3 个点 $a \leq x_1 \leq x_2 \leq x_3 \leq b$ 使得

$$P_1(x_k) - f(x_k) = (-1)^k \sigma \max_{a \leq x \leq b} |P_1(x) - f(x)|$$

由于 $f''(x)$ 在 (a, b) 内不变号, 故 $f'(x)$ 单调, $f'(x) - a_1$ 在 (a, b) 内只有一个零点, 记为 x_2 , 于是

$$P_1'(x_2) - f'(x_2) = a_1 - f'(x_2) = 0, \quad \text{即 } f'(x_2) = a_1$$

另外两个偏差点必在区间端点, 即 $x_0 = a, x_1 = b$, 且满足

$$P_1(a) - f(a) = P_1(b) - f(b) = -[P_1(x_2) - f(x_2)]$$

由此得到

$$\begin{cases} a_0 + a_1a - f(a) = a_0 + a_1b - f(b) \\ a_0 + a_1a - f(a) = f(x_2) - (a_0 + a_1x_2). \end{cases}$$

解得

$$\begin{aligned} a_1 &= \frac{f(b) - f(a)}{b - a} = f'(x_2) \\ a_0 &= \frac{f(a) + f(x_2)}{2} - \frac{f(b) - f(a)}{b - a} \frac{a + x_2}{2} \end{aligned}$$

例 3.4 $f(x) = \sqrt{x^2 + 1}$, 求 $[0, 1]$ 上的最佳一次逼近多项式。★★★★☆

解 先求 x_2 和 $f(x_2)$

$$\begin{aligned} f'(x_2) &= \frac{x_2}{\sqrt{x_2^2 + 1}} = \frac{f(1) - f(0)}{1 - 0} = \sqrt{2} - 1 \approx 0.414 \\ \Rightarrow x_2 &= \sqrt{\frac{\sqrt{2} - 1}{2}} \approx 0.4551, \quad f(x_2) = \sqrt{1 + x_2^2} = 1.0986 \end{aligned}$$

3.2 最佳平方逼近

定义 3.4 (正交函数) 若 $f(x), g(x) \in C[a, b]$ 满足

$$(f, g) = \int_a^b \rho(x) f(x) g(x) dx = 0,$$

则称 f 与 g 在 $[a, b]$ 上带权 $\rho(x)$ 正交。若函数族 $\varphi_0(x), \dots, \varphi_n(x)$ 满足关系

$$(\varphi_j, \varphi_k) = \int_a^b \rho(x) \varphi_j(x) \varphi_k(x) dx = \begin{cases} 0, & j \neq k, \\ A_k > 0, & j = k, \end{cases}$$

则称 φ_k 是 $[a, b]$ 上带权 $\rho(x)$ 得正交族函数。

定理 3.5 若 $(f, g) \in C[a, b]$, 则有

$$\begin{aligned} |(f, g)| &\leq \|f\|_2 \|g\|_2 && \text{柯西不等式} \\ \|f + g\|_2 &\leq \|f\|_2 + \|g\|_2 && \text{三角不等式} \\ \|f + g\|_2^2 + \|f - g\|_2^2 &= 2(\|f\|_2^2 + \|g\|_2^2) && \text{平行四边形定律} \end{aligned}$$

定义 3.5 (最佳平方逼近函数) 设 $f \in [a, b]$, 若 $\exists \varphi^* \in \Phi = \text{Span}\{\varphi_0, \dots, \varphi_n\}$ 使得

$$\|f - \varphi^*\|_2^2 = \inf_{\varphi \in \Phi} \|f - \varphi\|_2^2$$

则称 φ^* 为 f 在 Φ 中的最佳平方逼近函数。

注 上述问题等价于求多元函数

$$I(a_0, a_1, \dots, a_n) = \int_a^b \rho(x) \left[\sum_{j=0}^n a_j \varphi_j(x) - f(x) \right]^2 dx$$

的最小值。由于 $I(a_0, a_1, \dots, a_n)$ 是关于 a_0, a_1, \dots, a_n 的二次函数, 利用多元函数极值的必要条件

$$\frac{\partial I}{\partial a_k} = 2 \int_a^b \rho(x) \left[\sum_{j=0}^n a_j \varphi_j(x) - f(x) \right] \varphi_k(x) dx = 0, \quad (k = 0, 1, \dots, n),$$

$$\int_a^b \rho(x) \varphi_k(x) \sum_{j=0}^n a_j \varphi_j(x) dx = \int_a^b \rho(x) f(x) \varphi_k(x) dx, \quad (k = 0, 1, \dots, n),$$

于是有 **法方程**

$$\sum_{j=0}^n (\varphi_j, \varphi_k) a_j = (f, \varphi_k), k = 0, \dots, n$$

系数矩阵 A 为

$$A = \begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix}$$

例 3.5 设 $f(x) = \sqrt{1+x^2}$, 求 $[0, 1]$ 上的一次最佳平方逼近多项式 $p_1^*(x) = a_0^* + a_1^*x$ ★★★★★

解: 系数:

$$\begin{aligned}(\varphi_0, \varphi_0) &= 1, \quad (\varphi_0, \varphi_1) = \frac{1}{2}, \quad (\varphi_1, \varphi_1) = \frac{1}{3} \\(f, \varphi_0) &= \int_0^1 f(x) \cdot 1 dx, \quad (f, \varphi_1) = \int_0^1 f(x) \cdot x dx\end{aligned}$$

3.3 正交多项式

若取 $\{\varphi_k(x)\}_{k=0}^n$ 为正交多项式族, 求 f 在 $\Phi = \text{Span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$ 上的最佳平方逼近, 此时 **法方程** 的系数矩阵 **A** 为 **对角阵**。

$$a_k^* = \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)}, \quad k = 0, 1, \dots, n$$

定义 3.6 (正交多项式族) 若 φ_n 是首项次数 $a_n \neq 0$ 的 n 次多项式, 若

$$(\varphi_i, \varphi_j) = \int_a^b \varphi_i \varphi_j \rho(x) dx = \begin{cases} 0 & i \neq j \\ A_i \neq 0 & i = j \end{cases}$$

则称多项式族序列 $\{\varphi_i\}_0^\infty$ 是在 $[a, b]$ 上带权 $\rho(x)$ 的正交多项式族, φ_n 是在 $[a, b]$ 上带权 ρ 的正交多项式序列。

定义 3.7 (施密特正交化) x^n 减去投影到 $1, \dots, x^{n-1}$ 方向的分量:

- $\frac{(x^n, \varphi_k)}{\|\varphi_k\|_2}$: x^n 投影到 φ_k 方向的长度
- $\frac{\varphi_k}{\|\varphi_k\|_2}$: φ_k 方向的单位向量

序列 $\{x^n\}_0^\infty$ **线性无关且正交**。

$$\varphi_0(x) = 1, \quad \varphi_n(x) = x^n - \sum_{k=0}^{n-1} \frac{(x^n, \varphi_k)}{(\varphi_k, \varphi_k)} \varphi_k$$

定理 3.6 设 $\{\varphi_n\}_0^\infty$ 在 $[a, b]$ 上带权 ρ 的正交多项式序列, 则 $\varphi_n (n \geq 1)$ 的 n 个根都是单重实根, 且都在 (a, b) 内。

证明. 设 $\varphi_n(x)$ 有 m 个奇数重根 ($m \leq n$), 记为 x_1, \dots, x_m , 证明上述定理就是证明 $m = n$ 。

记

$$q(x) = (x - x_1) \cdots (x - x_m)$$

那么 $\varphi_n(x)q(x)$ 在 (a, b) 内不变号,

$$(\varphi_n(x), q(x)) = \int_a^b \varphi_n(x)q(x)dx \neq 0$$

因为 $(q(x))$ 可以表示为正交多项式序列 $\{\varphi_n\}_0^n$ 的线性组合), 那么若 $m < n$, 则 $(\varphi_n(x), q(x)) = 0$ 。故而 $m = n$, 即 $\varphi_n(x)$ 有 n 个单根。证毕!

定义 3.8 (勒让德 (Legendre) 多项式) 区间为 $[-1, 1]$ 和权函数为 $\rho = 1$, 由 $\{1, x, \dots\}$ 正交化得到的多项式称为 Legendre 多项式。

下面试着写几个 Legendre 多项式

- $P_0(x) = 1$
- $P_1(x) = x$
- $P_2(x)$

$$\begin{aligned} P_2(x) &= x^2 - \frac{(x^2, 1)}{(1, 1)} \cdot 1 - \frac{(x^2, x)}{(x, x)} \cdot x \\ &= x^2 - \frac{\int_{-1}^1 x^2 \cdot 1 dx}{\int_{-1}^1 1 \cdot 1 dx} \cdot 1 - \frac{\int_{-1}^1 x^2 \cdot x dx}{\int_{-1}^1 x \cdot x dx} \cdot x \\ &= x^2 - 2 \frac{1/3}{2} - \frac{0}{2/3} x = x^2 - \frac{1}{3} \end{aligned}$$

通项可以写为

$$P_0(x) = 1, P_n(x) = \frac{1}{2^n n!} \frac{d^n}{dx^n} \{(x^2 - 1)^n\}, n = 1, 2, \dots$$

推论 Legendre 多项式有以下性质

1. 正交性

$$(P_m, P_n) = \begin{cases} 0, & m \neq n \\ \frac{2}{2n+1}, & m = n \end{cases}$$

2. 递推关系

$$(n+1)P_{n+1}(x) = (2n+1)xP_n(x) - nP_{n-1}(x), \quad n = 1, 2, \dots$$

3. 奇偶性

$$P_n(-x) = (-1)^n P_n(x)$$

定理 3.7 在所有首项系数为 1 的 n 次多项式中, Legendre 多项式 $\tilde{P}_n(x)$ 在 $[-1, 1]$ 上与零的平方误差最小。

证明. 设 $Q_n(x)$ 是首项系数为 1 的 n 次的多项式

$$Q_n(x) = \tilde{P}_n(x) + \sum_{k=1}^n a_k \tilde{P}_k(x)$$

$$\begin{aligned}
\|Q_n(x)\|_2^2 &= (Q_n(x), Q_n(x)) \\
&= (\tilde{P}_n(x) + \sum_{k=1}^{n-1} a_k \tilde{P}_k(x), \tilde{P}_n(x) + \sum_{k=1}^{n-1} a_k \tilde{P}_k(x)) \\
&= (\tilde{P}_n(x), \tilde{P}_n(x)) + \sum_{k=0}^{n-1} (a_k \tilde{P}_k, a_k \tilde{P}_k) \\
&\geq \|\tilde{P}_n(x)\|_2^2
\end{aligned}$$

当且仅当 $a_0 = a_1 = \cdots = a_{n-1} = 0$ 时取等号。证毕！

3.4 最小二乘法

定义 3.9 (最小二乘问题) 设 f 由函数表 (x_i, f_i) , $i = 1, 2, \dots, m$ 给出, 求 $\varphi^* \in \Phi = \text{Span}\{\varphi_0, \dots, \varphi_n\}, n < m$, 使

$$\|f - \varphi^*\|_2^2 = \sum_{i=0}^m [f_i - \varphi^*(x_i)]^2 \rho_i = \inf_{\varphi \in \Phi} \|f - \varphi\|_2^2$$

就是曲线拟合的最小二乘问题, 称 $\varphi^*(x)$ 为 f 在 Φ 中的最小二乘逼近函数。

求解上述问题也就是求


$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{nm} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

$Ax = b$ 无解

投影到以 A 的列向量为基的空间中

$$A^T Ax = A^T b$$

如图, 在三维空间 $O - xyz$ 中, $\overrightarrow{OA} = \alpha_1$, $\overrightarrow{OB} = \alpha_2$, $\overrightarrow{OP'} = b$ 。显然无解, 那么我们可以退而求其次找距离 $\overrightarrow{OP'}$ 最近的解。



4 数值积分与数值微分

4.1 数值积分基本概念

数值积分就是将定积分的计算用和式近似表示

$$I = \int_a^b f(x)dx \approx \sum_{k=0}^n A_k f(x_k)$$

其中 A_k 与被积函数 f 无关, 称为求积系数, x_k 为求积节点。

定义 4.1 (插值型求积公式) 在 $[a, b]$ 上给定 $n+1$ 个节点 $a \leq x_0 \leq x_1 \leq \cdots \leq x_n \leq b$, 以及相应的函数值 $f(x_0), \cdots, f(x_n)$

$$L_n(x) = \sum_{k=0}^n l_k(x) f(x_k)$$

$$\begin{aligned} I &= \int_a^b f(x)dx \approx \int_a^b L_n(x)dx \\ &= \int_a^b \sum_{k=0}^n f(x_k) l_k(x) dx = \sum_{k=0}^n \int_a^b f(x_k) l_k(x) dx \\ &= \sum_{k=0}^n f(x_k) \int_a^b l_k(x) dx = \sum_{k=0}^n A_k f(x_k) \end{aligned}$$

其中, $A_k = \int_a^b l_k(x) dx$

$n=1$ 时, 由

$$\begin{aligned} I(f) &= \int_a^b \frac{x-b}{a-b} f(a) + \frac{x-a}{b-a} f(b) dx \\ &= \frac{1}{2} \frac{(x-b)^2}{a-b} f(a) \Big|_a^b + \frac{1}{2} \frac{(x-a)^2}{b-a} f(b) \Big|_a^b \\ &= \frac{b-a}{2} [f(a) + f(b)] \end{aligned}$$

$A_0 = A_1 = \frac{b-a}{2}$, 该式称为 **梯形公式**。

例 4.1 设 $P_2(x)$ 是以 $0, h, 2h$ 为插值点的 $f(x)$ 的二次插值多项式, 用 $P_2(x)$ 导出计算积分 $I = \int_0^{3h} f(x)dx$ 的数值积分公式 I_h 。★★★★☆☆

解 易知:

$$\begin{aligned} P_2(x) &= \frac{(x-h)(x-2h)}{(0-h)(0-2h)} f(0) + \frac{(x-0)(x-2h)}{(h-0)(h-2h)} f(h) \\ &\quad + \frac{(x-0)(x-h)}{(2h-0)(2h-h)} f(2h) \end{aligned}$$

故而

$$I_h = \left[\frac{3}{2} f(0) + \frac{9}{2} f(2h) \right] h$$

定义 4.2 (求积公式的代数精确度) 若求积公式

$$I(f) = \sum_{k=0}^n A_k f(x_k)$$

对 $f(x) = 1, x, \dots, x^m$ 时精确成立, 而对 $f(x) = x^{m+1}$ 不精确成立, 则称求积公式具有 m 次代数精度。

- 当 $f(x) = 1$ 时, $\sum_{k=0}^n A_k = \int_a^b dx = b - a$
- 当 $f(x) = x$ 时, $\sum_{k=0}^n A_k x = \int_a^b dx = \frac{1}{2}(b^2 - a^2)$
-
- 当 $f(x) = x^m$ 时, $\sum_{k=0}^n A_k x^m = \int_a^b x^m dx = \frac{1}{m+1}(b^{m+1} - a^{m+1})$
- 当 $f(x) = x^{m+1}$ 时, $\sum_{k=0}^n A_k x^{m+1} \neq \int_a^b x^{m+1} dx$

$n+1$ 个点的插值型求积公式至少有 n 次代数精确度

定理 4.1 求积公式 $I(f) = \sum_{k=0}^n A_k f(x_k)$ 至少有 n 次代数精确度的充分必要条件是它是插值型的。

证明. 由插值余项定理, 可知

$$R[f] = I - I_n = \int_a^b \frac{f^{n+1}(\xi)}{(n+1)!} w_{n+1}(x) dx$$

如果是插值型的, $R[f] = 0$ 。证毕!

例 4.2 求积公式

$$\int_0^1 f(x) dx \approx A_0 f(0) + A_1 f(1) + B_0 f'(0),$$

已知其余项表达式为 $R(f) = k f'''(\xi), \xi \in (0, 1)$ 。试确定 A_0, A_1 及 B_0 , 使该求积公式具有尽可能高的代数精确度, 并给出代数精确度的次数及求积公式余项。★★★★★

解

- 当 $f(x) = 1$ 时, $A_0 + A_1 = 1$
- 当 $f(x) = x$ 时, $A_1 + B_0 = \frac{1}{2}$
- 当 $f(x) = x^2$ 时, $A_1 = \frac{1}{3}$

得到 $A_0 = \frac{2}{3}, A_1 = \frac{1}{3}, B_0 = \frac{1}{6}$, 公式的代数精确度为 2。
令 $f(x) = x^3$, 余项为

$$R[f] = \int_0^1 x^3 dx - \frac{2}{3} \cdot 0^3 - \frac{1}{3} \cdot 1^3 - \frac{1}{6} (3 \cdot 0)^2 - \frac{1}{12} = 3! f'''(\xi)$$

故而, $k = -\frac{1}{72}$ 。

例 4.3 确定求积公式中的待定系数 a , 使其代数精度尽量高, 并指出其具有的代数精度及余项★★★★★

$$\int_0^h f(x)dx \approx \frac{h}{2} [f(0) + f(h)] + ah^2 [f'(0) - f'(h)]$$

解

- 当 $f(x) = 1$ 时, $h = h + 0$ 恒成立
- 当 $f(x) = x$ 时, $\frac{h^2}{2} = \frac{h^2}{2} + 0$ 恒成立
- 当 $f(x) = x^2$ 时, $\frac{h^3}{3} = \frac{h^3}{2} + ah^2 \cdot (-2h)$, 得

$$a = -\frac{1}{12}$$

代数精度为 3。

定义 4.3 对任给 $\varepsilon > 0$, 若 $\exists \delta > 0$, 只要 $|f(x_k) - \tilde{f}_k| \leq \delta (k = 0, 1, \dots, n)$ 就有

$$|I_n(f) - I_n(\tilde{f})| = \left| \sum_{k=0}^n A_k (f(x_k) - \tilde{f}_k) \right| \leq \varepsilon$$

成立, 则称求积公式是稳定的。

定理 4.2 若求积公式中系数 $A_k > 0 (k = 0, 1, \dots, n)$, 则此求积公式是稳定的。

4.2 Newton-Cotes 求积公式

定义 4.4 (Newton-Cotes 公式) 考虑等间距剖分情况下的插值型求积公式, 设等距节点: $x_k = a + kh$, 其中 $h = \frac{b-a}{n}$, $k = 0, 1, \dots, n$ 。插值基函数 $l_k(x)$ 为

$$l_k(x) = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j} = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{t - j}{k - j}$$

$$dx = \frac{b-a}{n} dt$$

$$\begin{aligned} \int_a^b f(x)dx &\approx \sum_{k=0}^n A_k f(x_k) = \sum_{k=0}^n f(x_k) \int_a^b l_k(x)dx \\ &= \sum_{k=0}^n f(x_k) \int_0^n \frac{b-a}{n} \prod_{\substack{j=0 \\ j \neq k}}^n \frac{t-j}{k-j} dt \\ &= (b-a) \sum_{k=0}^n C_k^{(n)} f(x_k) + R_n[f] \end{aligned}$$

其中, $C_k^{(n)} = \frac{1}{n} \int_0^n \prod_{\substack{j=0 \\ j \neq k}}^n \frac{t-j}{k-j} dt$

下面列出了一些 Cotes 系数

n	$C_k^{(n)}$			
1	$\frac{1}{2}$	$\frac{1}{2}$		
2	$\frac{1}{6}$	$\frac{4}{6}$	$\frac{1}{6}$	
3	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{3}{8}$	$\frac{1}{8}$

定理 4.3 当阶数 n 为偶数时, Newton-Cotes 公式至少有 $n+1$ 次代数精度。

注 梯形公式:

$$I(f) = \frac{b-a}{2} [f(a) + f(b)]$$

$$E(f) = \int_a^b \frac{f''(\xi)}{2} (x-a)(x-b) dx = -\frac{(b-a)^3}{12} f''(\eta)$$

注 Simpson 公式:

$$I(f) = \frac{b-a}{6} \left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right]$$

$$E(f) = -\frac{(b-a)^5}{2880} f^{(4)}(\eta)$$

4.2.1 复化求积法及其收敛性

定义 4.5 (复化求积公式) 考虑等间距剖分情况下的插值型求积公式, 设等距节点: $x_k = a + kh$, 其中 $h = \frac{b-a}{n}$, $k = 0, 1, \dots, n$ 。先用低阶的 Newton-Cotes 公式求得每个子区间 $[x_k, x_{k+1}]$ 上的积分值 I_k 然后再求和用作为所求分的近似值, 然后再求和。

$$\begin{aligned} \int_a^b f(x) dx &\approx T_n(f) \\ &= \sum_{k=0}^{n-1} \frac{h}{2} [f(x_k) + f(x_{k+1})] \\ &= \frac{h}{2} [f(a) + 2 \sum_{k=1}^{n-1} f(x_k) + f(b)] \end{aligned}$$

其积分余项

$$\begin{aligned} I - T_n &= \sum_{k=0}^{n-1} \left[-\frac{h^3}{12} f''(\eta_k) \right] \\ &= -\frac{h^3}{12} n \sum_{k=0}^{n-1} \left[\frac{f''(\eta_k)}{n} \right] \\ &= -\frac{b-a}{12} h^2 f''(\eta). \end{aligned}$$

最后一个 = 这里用到连续函数介值定理

这里称 Simpson 是 2 阶收敛的。

注 梯形公式

$$I_1(f) = \frac{b-a}{2}[f(a) + f(b)] \quad E_1(f) = -\frac{(b-a)^3}{12}f''(\eta)$$

复合梯形公式

$$\int_a^b f(x)dx \approx T_n(f) = \frac{h}{2}[f(a) + 2\sum_{k=1}^{n-1} f(x_k) + f(b)]$$

误差

$$E_n(f) = -\frac{b-a}{12}h^2f''(\eta), \quad \eta \in (a, b)$$

注 Simpson 求积公式

$$I_2(f) = \frac{b-a}{6}[f(a) + 4f(\frac{a+b}{2}) + f(b)] \quad E_2(f) = -\frac{(b-a)^5}{2880}f^{(4)}(\eta)$$

复合 Simpson 求积公式

$$\int_a^b f(x)dx \approx S_n(f) = \frac{h}{6}[f(a) + 4\sum_{k=0}^{n-1} f(x_{k+\frac{1}{2}}) + 2\sum_{k=1}^{n-1} f(x_k) + f(b)]$$

误差

$$E_n(f) = -\frac{b-a}{2880}h^4f^{(4)}(\eta), \quad \eta \in (a, b)$$

注 Romberg 算法:

- 梯形公式, Simpson 公式, Cotes 公式的代数精度分别为 1 次, 3 次和 5 次
- 复化梯形、复化 Simpson、复化 Cotes 公式的收敛阶分别为 2 阶、4 阶和 6 阶

定义 4.6 (求积公式收敛阶) 若一种复化求积公式 I_n 当 $h \rightarrow 0$ 时成立

$$\frac{I - I_n}{h^p} \rightarrow C (C \neq 0)$$

则称求积公式 I_n 是 p 阶收敛的。

4.3 Romberg 算法

将定积分 $I = \int_a^b f(x) = dx$ 的积分区间 $[a, b]$ 分割为 n 等份, 复化梯形 (Trapz) 公式为

$$T_n = \frac{b-a}{2n}[f(a) + 2\sum_{j=1}^{n-1} f(x_j) + f(b)]$$

如果将 $[a, b]$ 分割为 $2n$ 等份, 则

$$T_{2n} = \frac{b-a}{4n} [f(a) + 2 \sum_{j=1}^{n-1} f(x_j) + 2 \sum_{j=0}^{n-1} f(x_{j+\frac{1}{2}}) + f(b)]$$

$$T_{2n} = \frac{1}{2}T_n + \frac{b-a}{2n} \sum_{j=0}^{n-1} f(x_{j+\frac{1}{2}})$$

注 递推得梯形公式

$$\begin{cases} T_0(0) = \frac{b-a}{2} [f(a) + f(b)] \\ T_0(k) = \frac{1}{2}T_0(k-1) + \frac{b-a}{2^k} \sum_{j=0}^{2^{k-1}-1} f\left(a + (2j+1)\frac{b-a}{2^k}\right) \end{cases}$$

例 4.4 已知 $S_n = n \sin \frac{\pi}{n} = \pi - \frac{\pi^3}{3!n^2} + \frac{\pi^5}{5!n^4} - \cdots$, 如果采用 Richardson 外推法来基于 S , 计算 π 的值, 那么下列公式中的加权系数分别是多少?★★★★★

解

1. $\pi \approx \alpha_1 S_3 + \alpha_2 S_6$ 有

$$\begin{cases} \alpha_1 + \alpha_2 = 1 \\ -\alpha_1/9 - \alpha_2/36 = 0 \end{cases}$$

解得:

$$\alpha_1 = -\frac{1}{3}, \alpha_2 = \frac{4}{3}$$

2. $\pi \approx \beta_1 S_3 + \beta_2 S_9$ 有

$$\begin{cases} \alpha_1 + \alpha_2 = 1 \\ -\alpha_1/9 - \alpha_2/81 = 0 \end{cases}$$

解得:

$$\beta_1 = -\frac{1}{8}, \beta_2 = \frac{9}{8}$$

例 4.5 外推加速公式★★★★★

$$\lambda_1 F(h) = a + a_1 h^p + o(h^8)$$

$$\lambda_2 F(h) = a + a_1 \left(\frac{h}{2}\right)^p + o(h^8)$$

解

$$\lambda_1 F(h) + \lambda_2 F(h) = (\lambda_1 + \lambda_2)a + a_1 h^p (\lambda_1 + \frac{\lambda_2}{2^p})$$

$$\begin{cases} \lambda_1 + \lambda_2 = 1 \\ \lambda_1 + \frac{\lambda_2}{2^p} = 0 \end{cases}$$

得到

$$\begin{cases} \lambda_1 = -\frac{1}{2^p - 1} \\ \lambda_2 = \frac{1}{2^p - 1} \end{cases}$$

例 4.6 由复化梯形公式得余项公式★★★★★

解

$$I(f) - T_n = -\frac{b-a}{12}h^2 f''(\eta)$$

有

$$I(f) - T_{2n} = -\frac{b-a}{12}\frac{h^2}{4}f''(\eta)$$

结合二者可以得到

$$\begin{cases} \lambda_1 T_n = \lambda_1 I(f) + \lambda_1 \cdot \left[-\frac{b-a}{12}h^2 f''(\eta) \right] \\ \lambda_2 T_{2n} = \lambda_2 I(f) + \lambda_2 \cdot \left[-\frac{b-a}{12}\frac{h^2}{4}f''(\eta) \right] \end{cases}$$

那么

$$\begin{cases} \lambda_1 + \lambda_2 = 1 \\ -\lambda_1 - \frac{1}{4}\lambda_2 = 0 \end{cases}$$

解得

$$\begin{cases} \lambda_1 = -\frac{1}{3} \\ \lambda_2 = \frac{4}{3} \end{cases}$$

可以得到外推加速公式

$$I(f) \approx \frac{4}{3}T_{2n} - \frac{1}{3}T_n$$

4.4 高斯 (Gauss) 公式

考虑带权积分 $I(f) = \int_a^b f(x)\rho(x)dx$, 寻找形如

$$I(f) \approx \sum_{k=0}^n A_k f(x_k) = I_n(f)$$

的求积公式使它具有最高的代数精确度。式中含有 $2n+2$ 个待定参数 $x_k, A_k (k = 0, 1, \dots, n)$ 适当选择这些参数, 有可能使得求积公式具有 $2n+1$ 次代数精度。

定义 4.7 (Gauss 型求积公式) 具有最高代数精度的插值型求积公式称为 Gauss 型求积公式, 相应的求积节点 $a \leq x_0 < x_1 < \dots < x_n \leq b$ 称为 Gauss 点。

当插值型节点个数比较多时, 方程求解比较困难。因此我们可以先找出满足条件的插值节点 (Gauss 点)。

定理 4.4 插值型求积公式的求积节点 $\{x_k\}_{k=0}^n$ 是高斯点的充要条件是: 在 $[a, b]$ 上以这组节点为根的多项式 $\omega_{n+1}(x) = (x - x_0)(x - x_1) \cdots (x - x_n)$ 与任何次数 $\leq n$ 的多项式 $P(x)$ 带权 $\rho(x)$ 正交, 即

$$\int_a^b P(x)\omega_{n+1}(x)\rho(x)dx = 0$$

证明. 先证明必要性: 即 $\{x_k\}_{k=0}^n$ 是高斯点 $\Rightarrow \int_a^b Q(x)\rho(x)dx = 0$

设 x_k 为 Gauss 点, 那么有

$$Q(x) = P(x)\omega_{n+1}(x)$$

是次数不超过 $(2n + 1)$ 次的多项式, 则

$$\int_a^b Q(x)\rho(x)dx = \sum_{k=0}^n A_k Q(x_k) = 0$$

前一个等号利用了高斯节点的定义, 后面是因为 $\omega_{n+1}(x_k) = 0$

再证明充分性: 即 $\int_a^b P(x)\omega_{n+1}(x)\rho(x)dx = 0 \Rightarrow \int_a^b P_{2n+1}(x)dx = \sum_{k=0}^n A_k P_{2n+1}(x_k)$

设 $P_{2n+1}(x)$ 是任意次数 $\leq 2n + 1$ 次的多项式

$$P_{2n+1}(x) = P(x)\omega_{n+1}(x) + Q(x)$$

其中 $P(x), Q(x)$ 是次数 $\leq n$ 的多项式

$$\begin{aligned} & \int_a^b P_{2n+1}(x)dx \\ &= \int_a^b P(x)\omega_{n+1}(x)\rho(x)dx + \int_a^b Q(x)dx \\ &= 0 + \sum_{k=0}^n A_k Q(x_k) = \sum_{k=0}^n A_k P_{2n+1}(x_k) \end{aligned}$$

最后一个等号是因为 $P(x_k)\omega_{n+1}(x_k) = 0$

故公式有 $2n + 1$ 次代数精度。证毕!

定理 4.5 Gauss 型求积公式的求积系数 $A_k > 0 (k = 0, 1, \cdots, n)$

证明. 设 $\{x_k\}$ 为高斯点, $l_k(x)$ 是 x_k 点对应的拉格朗日插值基函数, 那么有

$$0 < \int_a^b l_k^2(x)\rho(x)dx = \sum_{j=0}^n A_j l_k^2(x_j) = A_k$$

推论 Gauss 型求积公式是稳定的。

定理 4.6 设 $f \in C[a, b]$, 则 Gauss 型求积公式是收敛的, 即

$$\lim_{n \rightarrow \infty} I_n(f) = \int_a^b f(x) \rho(x) dx$$

证明. 仅对 $\rho(x) = 1$ 进行证明, 因 $f \in C[a, b]$, 由 Weierstrass 定理知, 对 $\forall \varepsilon > 0, \exists P_n(x)$, 使得

$$\begin{aligned} & \|f(x) - P_n(x)\|_\infty < \varepsilon \\ & \left| I_n(f) - \int_a^b f(x) dx \right| \\ & \leq \left| I_n(f) - I_n(P) + I_n(P) - \int_a^b f(x) dx \right| \\ & \leq |I_n(f) - I_n(P)| + \left| I_n(P) - \int_a^b f(x) dx \right| \end{aligned}$$

而

$$\begin{aligned} |I_n(f) - I_n(P)| & \leq \sum_{k=0}^n A_k |f(x_k) - P(x_k)| \\ & \leq \sum_{k=0}^n A_k \|f - P_n\|_\infty = (b-a) \|f - P_n\|_\infty \end{aligned}$$

又

$$\begin{aligned} \left| I_n(P) - \int_a^b f(x) dx \right| & \leq \int_a^b |P - f| dx \\ & \leq \|P - f\|_\infty (b-a) \end{aligned}$$

证毕!

定理 4.7 Gauss-Legendre 求积公式的余项

$$R(x) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \int_a^b \omega^2(x) dx$$

例 4.7 利用 Gauss-Legendre 求积公式求在 $[a, b]$ 区间内的求积公式

解

$$\int_a^b f(x) dx \stackrel{x=\frac{b+a}{2}+\frac{b-a}{2}t}{=} \frac{b-a}{2} \int_{-1}^1 F(t) dt \approx \frac{b-a}{2} \sum_{k=0}^n A_k F(t_k)$$

高斯点 t_0, t_1, \dots, t_n 时 P_{n+1} 的零点。

例 4.8 求两点 Gauss-Legendre 积分的求积公式, 并用其计算★★★★★

$$I = \int_0^{\frac{\pi}{2}} \sin x dx$$

解

$$I = \int_0^{\frac{\pi}{2}} \sin x dx = \frac{\pi}{4} \int_{-1}^1 \sin\left(\frac{\pi}{4} + \frac{\pi}{4}t\right) dt$$
$$t_0 = -\frac{1}{\sqrt{3}}, \quad t_1 = \frac{1}{\sqrt{3}}$$

例 4.9 区间 $[3, 5]$ 上两点 Gauss-Legendre 公式的求积节点分别为★★★★★

解

$$x_0 = 4 - \frac{1}{\sqrt{3}}, \quad x_1 = 4 + \frac{1}{\sqrt{3}}$$

注 Gauss-Chebyshev 公式

$$[-1, 1], \rho = \frac{1}{\sqrt{1-x^2}}$$

$T_n(x)$ 的零点为 $x_k = \frac{2k-1}{2n}\pi, \quad k = 1, 2, \dots, n$

$$\int_{-1}^1 f(x) \frac{1}{\sqrt{1-x^2}} dx \approx \frac{\pi}{n} \sum_{k=1}^n f(x_k)$$

4.4.1 固定部分节点的高斯型求积公式

在实际应用中有时希望预先固定高斯型公式的一个或几个求积节点。

例 4.10 假设求积公式中 m 个节点固定, n 个节点待定。★★★★☆

则该公式的代数精确度为 $[2n + m - 1]$

注 采用自适应 Simpson 公式计算 $I = \int_a^{a+h} f(x) dx$

$$S_1(a, a+h) = \frac{h}{6} \left[f(a) + 4f\left(a + \frac{h}{2}\right) + f(b) \right]$$


$$I - S_1(a, a+h) = -\frac{h^5}{2880} f^{(4)}(\eta)$$

$$S_2 = S_1\left(a, a + \frac{h}{2}\right) + S_1\left(a + \frac{h}{2}, a+h\right)$$

$$I - S_2(a, a+h) = -\frac{1}{2880} \left(\frac{h}{2}\right)^5 f^{(4)}(\bar{\eta})$$

$$S_1 - S_2 = \frac{1}{2880} \left(\frac{15}{16}\right) h^5 f^{(4)}(\bar{\eta})$$

$$I - S_2(a, a+h) \approx \frac{1}{15} |S_1(a, a+h) - S_2(a, a+h)| < \varepsilon$$



4.5 二重积分计算方法

$$\begin{aligned}
 I(f) &= \iint_{\Omega} f(x, y) dx dy \\
 &= \int_a^b dx \int_{\varphi(x)}^{\psi(x)} f(x, y) dy = \int_a^b F(x) dx \\
 &\approx \sum_{k=0}^n A_k F(x_k) \\
 &\approx \sum_{k=0}^n A_k \left[\sum_{l=0}^m B_{kl} f(x_k, y_l) \right]
 \end{aligned}$$

例 4.11 计算上述二重积分的梯形公式为

解

$$\begin{aligned}
 T(f) &= \frac{b-a}{2} \left[\frac{\psi(a) - \varphi(a)}{2} (f(a, \varphi(a)) + f(a, \psi(a))) \right. \\
 &\quad \left. + \frac{\psi(b) - \varphi(b)}{2} (f(b, \varphi(b)) + f(b, \psi(b))) \right]
 \end{aligned}$$

4.5.1 复合求积公式

考虑矩形区域的重积分 $\Omega = [a, b] \times [c, d]$

$$I(f) = \int_a^b \int_c^d f(x, y) dx dy$$

注 复合梯形公式

$$\begin{aligned}
 I(f) &= \iint_{\Omega} f(x, y) dx dy \\
 &\approx \frac{h_x h_y}{4} \sum_{i=0}^n \sum_{j=0}^m \lambda_{ij} f(x_i, y_j) \\
 \Lambda &= \begin{bmatrix} 1 & 2 & 2 & \cdots & 2 & 2 & 1 \\ 2 & 4 & 4 & \cdots & 4 & 4 & 2 \\ \vdots & \cdots & \vdots & \cdots & \cdots & \cdots & \cdots \\ 2 & 4 & 4 & \cdots & 4 & 4 & 2 \\ 1 & 2 & 2 & \cdots & 2 & 2 & 1 \end{bmatrix} = (\lambda_{ij})
 \end{aligned}$$

4.6 数值微分

4.6.1 机械求导公式

$$f'(x_0) = \lim_{h \rightarrow 0} \frac{f(x_0 + h) - f(x_0)}{h}$$
$$f'(x_0) \approx \frac{f(x_0 + h) - f(x_0)}{h} = f'(x_0) + \frac{f''(x_0)}{2}h^2$$

注 中点公式 (二阶截断误差)

$$G(h) = \frac{f(a+h) - f(a-h)}{2h} \quad h \text{ 过小, 两相近的数相减, 影响舍入误差}$$

$$G(h) = f'(a) + \frac{h^2}{3!}f'''(a) + \frac{h^4}{5!}f^{(5)}(a) + \cdots \quad h \text{ 小, 截断误差小}$$

- 从舍入误差看, h 不宜过小
- 从截断误差看, h 越小, 计算越准确

例 4.12 以下关于数值微分的说法 不正确 的是 ()

- A 在实际应用中, 基于插值多项式的微分方法, 其插值次数不能太高
- B 近似导数 $f'(x)$ 的数值微分公式 $\frac{f(x_0+h)-f(x_0-h)}{2h}$ 和 $\frac{f(x_0)-4f(x_0+h)+3f(x_0+2h)}{2h}$ 误差阶相同
- C 数值微分公式的误差包括截断误差和舍入误差两部分
- D 当插值多项式 $L_n(x)$ 收敛于 $f(x)$ 时, 其导数 $L'_n(x)$ 收敛于 $f'(x)$

定义 4.8 (插值型求导公式) 建立 $f(x)$ 的插值多项式 $P_n(x)$, 用 $P'_n(x)$ 作为 $f'(x)$ 的近似值

$$f'(x_k) - P'_n(x_k) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega'_{n+1}(x_k)$$

其中 $\omega'_{n+1}(x_k) = (x - x_0)(x - x_1)(x - x_{k-1}) \cdots (x - x_{k+1})(x - x_n)$.

两点公式: 给定两个节点 x_0, x_1 , 做线性插值多项式 $P_1(x)$

$$P'_1(x_0) = P'_1(x_1) = \frac{f(x_1) - f(x_0)}{h}$$

$$f'(x_0) = P'_1(x_0) - \frac{h}{2}f''(\xi) \quad f'(x_1) = P'_1(x_1) + \frac{h}{2}f''(\xi)$$

三点公式: 给定三个节点 x_0, x_1, x_2 , 做二次插值多项式 $P_2(x)$

$$P'_2(x_0) = \frac{-f(x_2) + 4f(x_1) - 3f(x_0)}{2h}$$

$$P'_2(x_1) = \frac{f(x_2) - f(x_0)}{2h}$$

$$P'_2(x_2) = \frac{3f(x_2) - 4f(x_1) + f(x_0)}{2h}$$

以上公式近似相应导数的误差分别为 $\frac{h^2}{3}f'''(\xi)$, $-\frac{h^2}{6}f'''(\xi)$, $\frac{h^2}{3}f'''(\xi)$.

5 微分方程数值解的基本概念（没有大题）

5.1 微分方程数值解的基本概念

定理 5.1 如果方程 $\begin{cases} \frac{dy}{dx} = f(x, y), \\ y(x_0) = y_0. \end{cases}$ 中右端函数 $f(x, y)$ 满足

1. $f(x, y)$ 是实值函数
2. $f(x, y)$ 在矩形区域 $\Omega = \{(x, y) | x \in [x_0, T], y \in (-\infty, +\infty)\}$ 内连续
3. $f(x, y)$ 关于 y 满足 Lipschitz 条件：即存在正常数 L ，使得对任意 $x \in [x_0, T]$ ，均成立不等式

$$|f(x, y_1) - f(x, y_2)| \leq L|y_1 - y_2|$$

则方程存在唯一解 $y(x) \in C^1[x_0, T]$

定义 5.1 (扰动问题) 考虑扰动问题 $\begin{cases} \frac{dy}{dx} = f(x, y) + \delta(x), x_0 \leq x \leq T, \\ y(x_0) = y_0 + \varepsilon. \end{cases}$

例 5.1 以下初值问题是否关于数据的扰动稳定？

$$\begin{cases} \frac{du}{dt} = 100u - 101e^{-t} \\ u(0) = 1 \end{cases}$$

A 是

B 否

解 原问题的通解为

$$\begin{aligned} u(t) &= e^{-\int -100dt} \left(\int -101e^{-t} e^{\int -100dt} dt + C \right) \\ &= e^{100t} (e^{-101t} + C) \end{aligned}$$

代入初始条件 $u(0) = 1$ 得到

$$u(t) = e^{-t}$$

现在有初值的扰动 $u(0) = 1 + \varepsilon$ 得到

$$u(t) = e^{-t} + \varepsilon e^{100t}$$

显然对 $\forall \varepsilon > 0$, $u(t; \varepsilon)$ 偏离真解很大，故问题不稳定。

5.2 Euler 方法

定义 5.2 (Euler 方法) 考虑问题

$$\begin{cases} \frac{dy(x)}{dx} = f(x, y(x)), x_0 \leq x \leq T, \\ y(x_0) = y_0. \end{cases}$$

将区域 $[x_0, T]$ 剖分成 m 等份, 步长 $h = \frac{T - x_0}{m}$, 网点 $x_n = x_{n-1} + h = x_0 + (n-1)h, n = 1, 2, \dots, m$.

注 梯形法

$$y(x_{n+1}) = y(x_n) + \frac{h}{2}[f(x_n, y(x_n)) + f(x_{n+1}, y(x_{n+1}))] + R_n^{(1)}$$

$$R_n^{(1)} = -\frac{h^3}{12}y'''(\xi), x_n < \xi < x_{n+1}$$

$$y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, y_{n+1})]$$

- 梯形法为二阶方法

$$|y(x_n) - y_n| = O(h^2), \text{ 当 } h \rightarrow 0 \text{ 时}$$

- 梯形法为单步隐式方法
- 梯形法计算格式

$$\begin{cases} y_{n+1}^{(0)} = y_n + hf(x_n, y_n), \\ y_{n+1}^{(m+1)} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, y_{n+1}^{(m)})], \\ m = 0, 1, 2, \dots \end{cases}$$

- 梯形格式收敛的条件 是什么?

$$y_{n+1}^* = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, y_{n+1}^*)]$$

记 $y_{n+1}^{(m)} - y_{n+1}^* = \varepsilon^m$, 则

$$\begin{aligned} |\varepsilon^{(m+1)}| &= \frac{h}{2} [f(x_{n+1}, y_{n+1}^{(m)}) + f(x_{n+1}, y_{n+1}^*)] \\ &\leq \frac{hL}{2} |y_{n+1}^{(m)} - y_{n+1}^*| = \frac{hL}{2} \varepsilon^{(m)} \\ &= \left(\frac{hL}{2}\right)^m \varepsilon^{(0)} \end{aligned}$$

$$\lim_{m \rightarrow \infty} |\varepsilon^{(m+1)}| \implies \frac{hL}{2} < 1$$

例 5.2 下列关于梯形法的叙述错误的是★★★★☆☆

- A 梯形法是一个显式方法
- B 梯形法的整体截断误差是 $O(h^3)$
- C 梯形法是一个稳定的方法
- D 梯形法的迭代步长可以任取

注 改进 Euler 法

$$\begin{cases} \bar{y}_{n+1} = y_n + hf(x_n, y_n) & \text{预测} \\ y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, \bar{y}_{n+1})] & \text{校正} \end{cases}$$

预测校正格式还可写为

$$y_{n+1} = y_n + \frac{h}{2} \left[f(x_n, y_n) + f(x_n + h, y_n + hf(x_n, y_n)) \right]$$

$$\begin{cases} y_p = y_n + hf(x_n, y_n) \\ y_c = y_n + hf(x_{n+1}, y_p) \\ y_{n+1} = \frac{1}{2}[y_n + y_p] \end{cases}$$

例 5.3 改进 Euler 法是 [单] 步 (填“单”或“多”) [显] 格式 (填“显”或“隐”) 格式★★★★☆☆

5.3 Runge-Kutta 方法

定义 5.3 (Taylor 级数法)

$$y(x_0 + h) = y(x_0) + hy'(x_0) + \frac{h^2}{2}y''(x_0) + \cdots + \frac{h^q}{q!}y^{(q)}(x_0) + O(h^{q+1})$$

$$\begin{aligned} y'(x_0) &= \frac{d}{dx}f(x, y)|_{x=x_0} = (f'_x + f'_y \frac{dy}{dx})|_{x=x_0} \\ &= f'_x(x_0, y_0) + f'_y(x_0, y_0)f(x_0, y_0) \end{aligned}$$

$$y_{n+1} = y_n + hy'_n + \frac{h^2}{2}y''_n + \cdots + \frac{h^q}{q!}y^{(q)}_n$$

注 Taylor 级数法优缺点:

- 优点: 可达任意阶精度
- 缺点: 求导复杂, 不实用

注 Runge-Kutta 方法的基本思想

$$\frac{y(x_{n+1}) - y(x_n)}{h} = y'(x_n + \theta h)$$

$$\begin{aligned} y(x_{n+1}) - y(x_n) &= \int_{x_n}^{x_{n+1}} f(x, y) dx \\ &= f(x_n + \theta h, y(x_n + \theta h))h \end{aligned}$$

定义 5.4 (Runge-Kutta 法) 设 s 是一个正整数代表使用函数值 f 的个数, α_i, β_{ij} 和 W_i 是一些待定的权因子 (为实数), 方法

$$y_{n+1} = y_n + h \sum_{i=1}^s W_i K_i$$

其中 K_i 满足下列方程:

$$\begin{aligned} K_1 &= f(x_n, y(x_n)), K_2 = f(x_n + \alpha_2 h, y(x_n) + h\beta_{21}K_1) \\ K_3 &= f(x_n + \alpha_3 h, y(x_n) + h\beta_{31}K_1 + h\beta_{32}K_2) \\ &\dots\dots\dots \\ K_s &= f(x_n + \alpha_s h, y(x_n) + h \sum_{j=1}^{s-1} \beta_{sj} K_j) \end{aligned}$$

被称为一阶常微分方程的 s 级显式 Runge-Kutta 方法。

注 Runge-Kutta 方法可采用 Butcher 表表示

$$\begin{aligned} y_{n+1} &= y_n + h \sum_{i=1}^s W_i K_i \\ K_1 &= f(x_n, y(x_n)) \\ K_i &= f(x_n + \alpha_i h, y(x_n) + h\beta_{i1}K_1 + \dots + h\beta_{i,i-1}K_{i-1}) \end{aligned}$$

α_1	$\left \begin{array}{cccc} \beta_{21} & & & \\ \beta_{31} & \beta_{32} & & \\ \dots & \dots & \dots & \\ \beta_{s1} & \beta_{s2} & \dots & \beta_{s,s-1} \end{array} \right.$				
α_2					
α_3					
\dots					
α_s					
	W_1	W_2	\dots	W_{s-1}	W_s

例 5.4 4 级 Runge-Kutta 方法的局部截断误差是 [5] 阶.

注 s 级 Runge-Kutta 法的精度

- 当 $s \leq 4$ 时, s 级 RK 方法的阶 $q(s) = s$;
- 当 $s = 5, 6, 7$ 时, s 级 RK 方法的阶 $q(s) = s - 1$;
- 当 $s = 8, 9$ 时, s 级 RK 方法的阶 $q(s) = s - 2$;

- $q(10) < 8$.

以上都是单步法的代表。

注 一般单步法: 显式单步法的一般形式

$$y_{n+1} = y_n + h\varphi(x_n, y_n, h)$$

- Euler 法

$$\varphi(x, y, h) = f(x, y)$$

- Taylor 级数法

$$\varphi(x, y, h) = \sum_{j=1}^k \frac{h^{j-1}}{j!} y^{(j)}(x)$$

- s 级四阶 RK 方法

$$\varphi(x, y, h) = \frac{1}{6}(K_1 + 2K_2 + 2K_3 + K_4)$$

定义 5.5 (收敛) 若对于任意的初值 y_0 及任意 $x \in [x_0, T]$

$$\lim_{h \rightarrow 0} y_n = y(x_n),$$

称 $\varepsilon(x, y, h)$ 确定的单步方法是收敛的

定义 5.6 (单步法的阶数) 单步法

$$y_{n+1} = y_n + h\varphi(x_n, y_n, h)$$

称为 p 阶的, 是指: 对于真解 $y(x)$, p 是使关系式

$$y(x+h) - y(x) = h\varphi(x, y(x), h) + O(h^{p+1})$$

成立的最大整数.

定理 5.2 假设单步法具有 p 阶精度, 且增量函数 $\varepsilon(x, y, h)$ 关于满足 Lipschitz 条件:

$$|\varphi(x, y, h) - \varphi(x, \bar{y}, h)| \leq L_\varphi(y - \bar{y})$$

又设初值 $y_0 = y(x)$ 是准确的, 则整体截断误差为

$$y(x_n) - y_n = O(h^p)$$

证明.

$$\begin{cases} y_{n+1} = y_n + \varphi(x_n, y_n, h) \\ y(x_{n+1}) = y(x_n) + h\varphi(x_n, y(x_n), h) + Ch^{p+1} \end{cases}$$

令 $\varepsilon_n = y(x_n) - y_n$, 那么有

$$\begin{aligned} |\varepsilon_{n+1}| &\leq |\varepsilon_n| + h |\varphi(x_n, y(x_n), h) - \varphi(x_n, y_n, h)| + Ch^{p+1} \\ &\leq |\varepsilon_n| + hL|y(x_n) - y_n| + Ch^{p+1} \end{aligned}$$

所以

$$\begin{aligned} |\varepsilon_{n+1}| &\leq (1 + hL)|\varepsilon_n| + Ch^{p+1} \\ &\leq (1 + hL)|\varepsilon_{n-1}| + [(1 + hL) + 1] Ch^{p+1} \\ &\leq (1 + hL)^n |\varepsilon_0| + [(1 + hL)^n + (1 + hL)^{n-1} + \cdots + 1] Ch^{p+1} \\ &\leq (1 + hL)^n |\varepsilon_0| + \frac{1}{hL} Ch^{p+1} \end{aligned}$$

证毕!

例 5.5 分析改进 Euler 法的收敛性★★★★☆☆

$$\begin{cases} \bar{y}_{n+1} = y_n + hf(x_n, y_n) \\ y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, \bar{y}_{n+1})] \end{cases}$$

解

$$\varphi(x, y, h) = \frac{1}{2}[f(x, y) + f(x + h, y + hf(x, y))]$$

那么有

$$\begin{aligned} &|\varphi(x, y, h) - \varphi(x, \bar{y}, h)| \\ &\leq \frac{1}{2}|f(x, y) - f(x, \bar{y})| + \frac{1}{2}|f(x + h, y + hf(x, y)) - f(x + h, \bar{y} + hf(x, \bar{y}))| \\ &\leq \frac{L}{2}|y - \bar{y}| + \frac{L}{2}|(y - \bar{y}) + h[f(x, y) - f(x, \bar{y})]| \\ &\leq (L + \frac{L^2 h}{2})|y - \bar{y}| \end{aligned}$$

5.4 单步法的收敛性与稳定性

对于模型问题 $y' = \lambda y$, 考察格式的稳定性, 有 $y = Ce^{\lambda x}$

- Euler 法 $y_{n+1} = y_n + hf(x_n, y_n)$ (条件稳定)

根据 $\varepsilon_n = y_n - z_n$ 有

$$y_{n+1} = y_n + h\lambda y_n$$

$$z_{n+1} = z_n + h\lambda z_n$$

$$\varepsilon_{n+1} = (1 + h\lambda)\varepsilon_n$$

- 后退 Euler 法 $y_{n+1} = y_n + hf(x_{n+1}, y_{n+1})$ (无条件稳定)

$$y_{n+1} = y_n + h\lambda y_{n+1} \Rightarrow y_{n+1} = \frac{1}{1 - \lambda h} y_n$$

那么有

$$(1 - h\lambda)\varepsilon_{n+1} = \varepsilon_n$$

$$\varepsilon_{n+1} = \frac{|\varepsilon_n|}{|(1 - h\lambda)|} \leq |\varepsilon_n|$$

当 $|1 - h\lambda| > 1$, 即 $h \geq 0$ 时, 格式稳定

5.5 线性多步法 (1)

基于数值积分的构造方法

$$y(x_{n+k}) - y(x_{n-j}) = \int_{x_{n-j}}^{x_{n+k}} f(x, y(x)) dx$$

用 $f(x, y(x)) \approx P_q(x) = \sum_{i=0}^q f(x_{n-i}, y_{n-i}) L_i(x)$ 来估计, 其中

$$L_i(x) = \prod_{\substack{l=0 \\ l \neq i}}^q \frac{x - x_{n-l}}{x_{n-i} - x_{n-l}}.$$

得到

$$\begin{aligned} y(x_{n+k}) - y(x_{n-j}) &= \sum_{i=0}^q f(x_{n-i}, y_{n-i}) \int_{x_{n-j}}^{x_{n+k}} L_i(x) dx \\ &= \sum_{i=0}^q f(x_{n-i}, y_{n-i}) \int_{x_{n-j}}^{x_{n+k}} \prod_{\substack{l=0 \\ l \neq i}}^q \frac{x - x_{n-l}}{x_{n-i} - x_{n-l}} dx \\ &\stackrel{x=x_n+th}{=} \sum_{i=0}^q f(x_{n-i}, y_{n-i}) \int_{x_{n-j}}^{x_{n+k}} \prod_{\substack{l=0 \\ l \neq i}}^q \frac{(x_n + th) - (x_n - lh)}{(x_n - ih) - (x_n - lh)} dx \\ &= h \sum_{i=0}^q f(x_{n-i}, y_{n-i}) \int_{-j}^k \prod_{\substack{l=0 \\ l \neq i}}^q \frac{l+t}{l-i} dt \end{aligned}$$

线性多步法的计算公式

- $k=1, j=0$ 时, 得到 Adams 显式方法:

$$y_{n+1} = y_n + h \sum_{i=0}^q \beta_{qi} f_{n-i}$$

$$y_{n+1} = y_n + \frac{h}{24} (55f_n - 59f_{n-1} + 37f_{n-2} - 9f_{n-3})$$

- $k=0, j=1$ 时, 得到 Adams 隐式方法:

$$y_n = y_{n-1} + h \sum_{i=0}^q \beta_{qi} f_{n-i}$$

$$y_{n+1} = y_n + h[\beta_{q0} f_{n+1} + \beta_{q1} f_n + \cdots + \beta_{qq} f_{n-q+1}]$$

$$y_{n+1} = y_n + \frac{h}{24}(9f_{n+1} + 19f_n - 5f_{n-1} + f_{n-2})$$

例 5.6 假设网格点等间距分布, 空间步长为 h , 请采用数值积分方法基于 x_{n-1}, x_n, x_{n+1} 构造一个隐式多步法。★★★★★

解 3 个点, 对 2 阶拉格朗日多项式换元积分, 得到

$$\begin{aligned} & \int_{x_n}^{x_{n+1}} f_{n-1} \frac{(x-x_n)(x-x_{n+1})}{(x_{n-1}-x_n)(x_{n-1}-x_{n+1})} + f_n \frac{(x-x_{n-1})(x-x_{n+1})}{(x_n-x_{n-1})(x_n-x_{n+1})} \\ & + f_{n+1} \frac{(x-x_{n-1})(x-x_n)}{(x_{n+1}-x_{n-1})(x_{n+1}-x_n)} dx \\ & \stackrel{x=x_n+th}{=} h \int_0^1 f_{n-1} \frac{t(t-1)}{-1 \cdot (-2)} + f_n \frac{(t+1)(t-1)}{1 \cdot (-1)} + f_{n+1} \frac{(t+1)t}{2 \cdot 1} \\ & = h \left[\frac{-1}{12} f_{n-1} + \frac{2}{3} f_n + \frac{5}{12} f_{n+1} \right] \end{aligned}$$

故而, 隐式多步法可以构造为

$$y_{n+1} - y_n = h \left[\frac{-1}{12} f_{n-1} + \frac{2}{3} f_n + \frac{5}{12} f_{n+1} \right]$$

$$\Rightarrow y_{n+1} = y_n + \frac{h}{12} [5f_{n+1} + 8f_n - f_{n-1}]$$

注 基于 Taylor 展开的构造方法

- 线性 k 步法的一般形式

$$y_{n+1} = \sum_{k=0}^r \alpha_k y_{n-k} + h \sum_{k=-1}^r \beta_k f_{n-k}$$

例 5.7 关于前面预测-校正算法, 下列叙述正确的是? ★★★★★☆

- ☒ A 预测-校正算法是一个显式方法
- ☒ B 预测-校正算法是一个显式方法预测步和校正步的截断误差为同阶
- ☒ C 预测-校正算法的整体截断误差是 $O(h^5)$
- ☒ D 由于初始时刻无预测值和校正值, 所以可令它们的差为零, 然后多次校正

5.6 方程组与刚性问题

例 5.8 考虑方程组 $\begin{cases} \frac{dY}{dx} = JY, 0 \leq x \leq 1, \\ Y(0) = (2, 1, 2)^T \end{cases}$

$$\text{其中 } J = \begin{pmatrix} -0.1 & -49.9 & 0 \\ 0 & -50 & 0 \\ 0 & 70 & -30000 \end{pmatrix}$$

解 上述问题的解为

$$\begin{cases} Y_1(x) = e^{-0.1x} + e^{-50x} \\ Y_2(x) = e^{-50x} \\ Y_3(x) = e^{-50x} + e^{-30000x} \end{cases}$$

不同的解的分量有不同的衰减速度

考虑方程组

$$\frac{dY}{dx} = JY + Z$$

设 J 有互异的特征值 λ_k , 对应的特征向量为 C_k , 则方程组的通解为

$$Y = \sum_{k=1}^m U_k e^{\lambda_k x} C_k + V(x)$$

其中 Q_k 为常数, $V(x)$ 为特解

定义 5.7 (刚性) 上述线性方程组称为刚性的, 若 $\operatorname{Re}(\lambda_k) < 0, \max |\operatorname{Re}(\lambda_k)| \gg \min |\operatorname{Re}(\lambda_k)|$, 此时 $\frac{\max |\operatorname{Re}(\lambda_k)|}{\min |\operatorname{Re}(\lambda_k)|}$ 称为刚性比

例 5.9 一阶微分方程初值问题

$$\begin{cases} u_1' = -0.01u_1 - 99.99u_2 \\ u_2' = -100u_2 \\ u_1(0) = 2, u_2(0) = 1. \end{cases}$$

的刚性比 [10000]。★★★★☆

解

$$A = \begin{bmatrix} -0.01 & 99.99 \\ 0 & -100 \end{bmatrix}$$

特征值为 $\lambda_1 = -0.01, \lambda_2 = -100$ 。故而刚性比为 $\frac{100}{0.01} = 10000$

5.7 边值问题的解法

考虑两点边值问题

$$\begin{aligned} y'' &= f(x, y, y'), a < x < b, \\ y(a) &= \alpha \\ y(b) &= \beta \end{aligned}$$

注 试射法 (shooting): 将边值问题转化为初值问题求解, 反复调整初始时刻的斜率 $y'(a)$, 使得初值问题的解能够命中 $y(b) = \beta$. 试射法也称打靶法

$$\begin{aligned} y_1'' &= f(x, y_1, y_1') & y_2'' &= f(x, y_2, y_2') \\ y_1(a) &= \alpha & y_2(a) &= \alpha \\ y_1'(a) &= m_1 & y_2'(a) &= m_2 \end{aligned}$$

$$\begin{aligned} c_1 y_1(b) + c_2 y_1(b) &= y_1(b) \Rightarrow c_2 = \frac{\beta - y_1(b)}{y_2(b) - y_1(b)} \\ c_1 y_2(b) + c_2 y_2(b) &= y_2(b) \Rightarrow c_1 = \frac{\beta - y_2(b)}{y_1(b) - y_2(b)} \end{aligned}$$

$$\begin{aligned} y &= c_1 y_1 + c_2 y_2 \\ c_1 + c_2 &= 1 \\ c_1 y_1(b) + c_2 y_2(b) &= \beta \end{aligned}$$

注 有限差分法

$$\begin{cases} y'' = f(x, y, y'), a \leq x \leq b, \\ y(a) = \alpha, y(b) = \beta. \end{cases}$$

将求解区域 $[a, b]$ 分成 N 等份, 步长 $h = \frac{b-a}{N}$ 网点 $x_n = a + nh, n = 0, 1, 2, \dots, N$.

$$y''|_{x_n} = \frac{y_{n+1} - 2y_n + y_{n-1}}{h^2} \quad y'|_{x_n} = \frac{y_{n+1} - y_{n-1}}{2h} + O(h^2)$$

差分近似得到

$$\begin{aligned} \frac{y_{n+1} - 2y_n + y_{n-1}}{h^2} &= f(x_n, y_n, \frac{y_{n+1} - y_{n-1}}{2h}) \\ y_0 &= \alpha, y_N = \beta. \end{aligned}$$

$N+1$ 个差分点, $N-1$ 个未知量, $N-1$ 个差分方程

6 方程求根

6.1 非线性方程求根的基本概念

定义 6.1 (单根区间、多根区间、有根区间) 如果方程 $f(x) = 0$ 在区间 $[a, b]$ 上只有一个根、多个跟、至少有一个根, 称 $[a, b]$ 为单根区间、多根区间、有根区间。

6.2 跟的搜索与二分法

例 6.1 求方程 $f(x) = x^3 - 11.1x^2 + 38.8x - 41.77 = 0$ 的有根区间。

解 方程的三个有根区间为 $[2, 3]$, $[3, 4]$ 和 $[5, 6]$

注 逐步搜索法:

- 搜索步长的选取是逐步搜索法的关键, 当步长缩小时, 搜索步数增多, 计算量增大
- 如果精度要求比较高, 单用逐步搜索法不合算

注 二分法: 假设 $a_0 = a, b_0 = b$

- 取 $x_0 = \frac{a_0 + b_0}{2}$, 将区间 $[a_0, b_0]$ 分为两半
若 $f(a_0)f(x_0) > 0$, 则取 $a_1 = x_0, b_1 = b_0$, 否则取 $a_1 = a_0, b_1 = x_0$
- 取 $x_1 = \frac{a_1 + b_1}{2}$, 将区间 $[a_1, b_1]$ 分为两半
若 $f(a_1)f(x_1) > 0$, 则取 $a_2 = x_1, b_2 = b_1$, 否则取 $a_2 = a_1, b_2 = x_1$

6.3 不动点迭代法

定义 6.2 (不动点迭代法) 将非线性方程 $f(x) = 0$ 化为一个同解方程

$$x = \varphi(x)$$

任取一个初值 x_0 代入上式右端, 得到

$$x_1 = \varphi(x_0), x_2 = \varphi(x_1), \dots, x_{k+1} = \varphi(x_k)$$

求解非线性方程 $f(x) = 0$ 的不动点迭代法。

如果存在一点 x^* , 使得 $\lim_{k \rightarrow \infty} x_k = x^*$, 则称迭代法收敛, 否则称为发散。

定义 6.3 (压缩映射)

$$|x_k - x^*| = |\varphi(x_{k-1}) - \varphi(x^*)| \leq L|x_{k-1} - x^*| (0 < L < 1)$$

称为压缩映射。

定理 6.1 设迭代函数且满足 $\varphi(x) \in C[a, b]$ 且满足

1. $\forall x \in [a, b]$, 有 $\varphi(x) \in [a, b]$
2. 存在 $L \in (0, 1)$, 使得 $\forall x, y \in [a, b]$

$$|\varphi(x) - \varphi(y)| \leq L|x - y|$$

则

1. $\varphi(x)$ 在区间 $[a, b]$ 内存在唯一不动点
2. 对于任意初值 $x_0 \in [a, b]$, 由迭代法生成的迭代序列 $\{x_k\}$ 均收敛于 x^*

$$3. |x_k - x^*| \leq \frac{L}{1-L} |x_k - x_{k-1}|$$

$$4. |x_k - x^*| \leq \frac{L^k}{1-L} |x_1 - x_0|$$

证明. 证明 1: 令 $F(x) = \varphi(x) - x$, 则 $F(x) \in C[a, b]$ 且

$$F(a) = \varphi(a) - a \geq 0, F(b) = \varphi(b) - b \leq 0,$$

有闭区间连续函数的性质知道, $\exists x^* \in [a, b]$ 使得 $F(x^*) = \varphi(x^*) - x^*$

设 y^* 也是 $\varphi(x)$ 的不动点, 则

$$0 < |y^* - x^*| = |\varphi(y^*) - \varphi(x^*)| \leq L|y^* - x^*|$$

矛盾!

证明 2:

$$0 < |x_k - x^*| = |\varphi(x_{k-1}) - \varphi(x^*)| \leq \cdots \leq L^k |x_0 - x^*|$$

证明 3:

$$\begin{aligned} |x_k - x^*| &\leq L|x_{k-1} - x^*| \leq L(|x_{k-1} - x^k| + |x_k - x^*|) \\ \Rightarrow |x_k - x^*| &\leq \frac{L}{1-L} |x_k - x_{k-1}| \end{aligned}$$

证明 4:

$$\begin{aligned} |x_k - x^*| &\leq \frac{L}{1-L} |\varphi(x_{k-1}) - \varphi(x_{k-2})| \leq \cdots \leq \frac{L^k}{1-L} |x_1 - x_0| \\ \Rightarrow |x_k - x^*| &\leq \frac{L^k}{1-L} |x_1 - x_0| \end{aligned}$$

证毕!

注 利用拉格朗日中值定理

$$|\varphi(x) - \varphi(y)| = |\varphi'(\xi)| |x - y| \leq \underbrace{\max_{x \in [a, b]} |\varphi'(x)|}_{L} |x - y|$$

例 6.2 构造不同的迭代法求 $x^2 - 3 = 0$ 根 $x^* = \sqrt{3}$. 要求计算结果精确到小数点后第 7 位

- 迭代格式 1: $x_{k+1} = \frac{3}{x_k}$
- 迭代格式 2: $x_{k+1} = x_k - \frac{1}{4}(x_k^2 - 3)$
- 迭代格式 3: $x_{k+1} = \frac{1}{2} \left(x_k + \frac{3}{x_k} \right)$

上述迭代格式中收敛的是 [2,3]，收敛最快的是 [3]

解

$$\begin{aligned} |\varphi'_1(x)| &= \frac{3}{x^2} & |\varphi'_1(\sqrt{3})| &= 1 \\ |\varphi'_2(x)| &= \left|1 - \frac{x}{2}\right| & |\varphi'_2(\sqrt{3})| &= 1 - \frac{\sqrt{3}}{2} \\ |\varphi'_3(x)| &= \frac{1}{2} \left|1 - \frac{3}{x^2}\right| & |\varphi'_3(\sqrt{3})| &= 0 \\ |\varphi'_3(x)| &= \frac{1}{2} \left|1 - \frac{3}{x^2}\right|, & |\varphi'_3(\sqrt{3})| &= 0, |\varphi''_3(\sqrt{3})| = \frac{6}{(\sqrt{3})^3} \neq 0 \end{aligned}$$

迭代格式 3 是二阶收敛的

定义 6.4 (收敛) 若存在实数 $p \geq 1$ 和常数 $c > 0$ 满足

$$\lim_{k \rightarrow \infty} \frac{\varepsilon_{k+1}}{\varepsilon_k^p} = c$$

则称迭代法 p 阶收敛，当 $p = 1$ 时称为线性收敛， $p > 1$ 时称为超线性收敛， $p = 2$ 时称为平方收敛。

显然， p 越大，收敛速度也就越快。

注 如何确定 p ，从而确定收敛阶呢？

$$\begin{aligned} \varphi(x) &= \varphi(x^*) + \varphi'(x^*)(x - x^*) + \frac{\varphi''(x^*)}{2!}(x - x^*)^2 + \cdots \\ &\quad + \frac{\varphi^{(p-1)}(x^*)}{(p-1)!}(x - x^*)^{p-1} + \frac{\varphi^{(p)}(x^*)}{p!}(x - x^*)^p + \cdots \end{aligned}$$

如果 $\varphi'(x^*) = \varphi''(x^*) = \cdots = \varphi^{(p-1)}(x^*) = 0$ ，从而 $\varphi^{(p)}(x^*) \neq 0$

$$\begin{aligned} \varphi(x) &= \varphi(x^*) + \frac{\varphi^{(p)}(x^*)}{p!}(x - x^*)^p + \cdots \\ x_{k+1} &= \varphi(x_k) = \varphi(x^*) + \frac{\varphi^{(p)}(x^*)}{p!}(x_k - x^*)^p + \cdots \\ \frac{|x_{k+1} - x^*|}{|x_k - x^*|^p} &= \left| \frac{\varphi^{(p)}(x^*)}{p!} + \frac{\varphi^{(p+1)}(x^*)}{(p+1)!}(x_k - x^*) + \cdots \right| \rightarrow \left| \frac{\varphi^{(p)}(x^*)}{p!} \right|, (k \rightarrow \infty) \end{aligned}$$

即迭代法 $x_{k+1} = \varphi(x_k)$ 的收敛阶是 p

定理 6.2 如果迭代法迭代函数 $\varphi(x)$ 在根 x^* 附近满足

1. $\varphi(x)$ 存在 p 阶导数且连续；
2. $\varphi'(x^*) = \varphi''(x^*) = \cdots = \varphi^{(p-1)}(x^*) = 0$ ，而 $\varphi^{(p)}(x^*) \neq 0$

注 Aitken 加速方法

设 x_0 是根 x^* 的某个近似值，用迭代公式校正一次得，

$$x_1 = \varphi(x_0)$$

$$x_1 - x^* = \varphi(x_0) - \varphi(x^*) = \varphi'(\xi)(x_0 - x^*)$$

若将 x_1 再迭代一次得,

$$\begin{aligned} x_2 &= \varphi(x_1) \\ x_2 - x^* &= \varphi'(\eta)(x_1 - x^*) \\ \frac{x_1 - x^*}{x_2 - x^*} &\approx \frac{x_0 - x^*}{x_1 - x^*} \Rightarrow x^* \approx \frac{x_0 x_2 - x_1^2}{x_2 - 2x_1 + x_0} = x_0 - \frac{(x_1 - x_0)^2}{x_2 - 2x_1 + x_0} \end{aligned}$$

记

$$\bar{x}_{k+1} = x_k - \frac{(x_{k+1} - x_k)^2}{x_{k+2} - 2x_{k+1} + x_k}$$

可以证明,

$$\lim_{k \rightarrow \infty} \frac{\bar{x}_{k+1} - x^*}{x_k - x^*} = 0$$

定义 6.5 (Aitken 迭代法) 假设 $\{x_k\}$ 是由不动点迭代得到的序列,

$$\begin{cases} y_k = \varphi(x_k), z_k = \varphi(y_k), \\ x_{k+1} = x_k - \frac{(y_k - x_k)^2}{z_k - 2y_k + x_k} \end{cases} \quad (k = 0, 1, 2, \dots)$$

称上述公式为 Aitken 迭代法。

其中, 相当于将原来的迭代改为另一种不动点迭代,

$$x_{k+1} = \psi(x_k)$$

$$\psi(x) = x - \frac{[\varphi(x) - x]^2}{\varphi(\varphi(x)) - 2\varphi(x) + x}$$

例 6.3 迭代格式 1: $x_{k+1} = \frac{3}{x_k}, k = 0, 1, \dots$ ★★★★★

解 Aitken 加速后:

$$\begin{aligned} x_{k+1} &= \frac{x_k^2 + 3}{2x_k}, k = 0, 1, \dots \\ \psi'(x) &= \frac{1}{2} - \frac{3}{2x^2}, \psi'(\sqrt{3}) = 0 \\ \psi''(x) &= \frac{3}{x^3}, \psi''(\sqrt{3}) = \frac{1}{\sqrt{3}} \neq 0. \end{aligned}$$

6.4 Newton 迭代法

定义 6.6 (Newton 迭代法公式) 采用 Aitken 方法加速 $f(x) = 0$ 的迭代法: 令 $\varphi(x) = x + f(x)$, 设 $L = \varphi'(x) = 1 + f'(x)$

$$\begin{aligned} x_{k+1} &= x_k + f(x_k), \quad \bar{x}_{k+1} = x_k + f(x_k) \\ x_{k+1} &= \bar{x}_{k+1} + \frac{L}{1-L}(\bar{x}_{k+1} - x_k) \end{aligned}$$

记 $M = L - 1$, 则 $x_k + 1 = x_k - \frac{f(x_k)}{M}$

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, k = 0, 1, \dots$$

称为解方程 $f(x) = 0$ 的 Newton 迭代法。

注 Newton 迭代法几何解释: Newton 迭代法也称为切线法

$$f(x) \approx f(x_k) + f'(x_k)(x - x_k)$$

切线方程

$$f(x_k) + f'(x_k)(x - x_k) = 0 \Rightarrow x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

注 收敛性问题

- 若 x^* 是 $f(x) = 0$ 的一个单根, 则 $\varphi'(x^*) = 0$, 即 Newton 法在附近是平方收敛的.

$$\varphi'(x) = 1 - \frac{[f'(x)]^2 - f(x)f''(x)}{[f'(x)]^2} = \frac{f(x)f''(x)}{[f'(x)]^2}, \varphi'(x^*) = 0$$

- 若 x^* 是 $f(x) = 0$ 的 $m(m \geq 2)$ 重根, 则 Newton 法仅为线性收敛.

有 $f(x^*) = f'(x^*) = \dots = f^{(m-1)}(x^*) = 0$, 则

$$\begin{aligned} x_{k+1} - x^* &= x_k - x^* - \frac{f(x_k)}{f'(x_k)} \\ &= x_k - x^* - \frac{f^{(m)}(x^*) \frac{(x_k - x^*)^m}{m!} + o(x_k - x^*)^{m+1}}{f^{(m)}(x^*) \frac{(x_k - x^*)^{m-1}}{(m-1)!} + o(x_k - x^*)^{m-1}} \\ &= x_k - x^* - \frac{1}{m} \frac{f^{(m)}(x^*)(x_k - x^*)^m + o(x_k - x^*)^m}{f^{(m)}(x^*) + o(1)} \end{aligned}$$

有

$$\frac{x_{k+1} - x^*}{x_k - x^*} = 1 - \frac{1}{m} \quad (k \rightarrow \infty)$$

- 改进 $\varphi(x) = x - m \frac{f(x)}{f'(x)}$ 设 $f(x) = (x - x^*)^m g(x)$, $g(x^*) \neq 0$

$$\begin{aligned} \varphi(x) &= x - m \frac{f(x)}{f'(x)} = x - m \frac{(x - x^*)^m g(x)}{m(x - x^*)^{m-1} g(x) + (x - x^*)^m g'(x)} \\ &= x - m \frac{(x - x^*) g(x)}{m g(x) + (x - x^*) g'(x)} \end{aligned}$$

求导

$$\begin{aligned} \varphi'(x) &= 1 - m \frac{g(x)[m g(x) + (x - x^*) g'(x)] - (x - x^*) g(x)[\dots]}{[m g(x) + (x - x^*) g'(x)]^2} \\ \varphi'(x^*) &= 1 - m \frac{g(x^*) m g(x^*)}{[m g(x^*)]^2} = 0 \end{aligned}$$

- 或者改进, 记 $\mu(x) = \frac{f(x)}{f'(x)}$, 则可对 $\mu(x)$ 应用 Newton 法:

$$\varphi(x) = x - \frac{\mu(x)}{\mu'(x)}$$

$$\varphi(x) = x - \frac{f(x)f'(x)}{[f'(x)]^2 - f(x)f''(x)}$$

例 6.4 构造一个二阶收敛的格式计算方程★★★★☆☆

$$x^3 + x^2 - 3x - 3 = 0$$

的二重根 $x = \sqrt{3}$

解

$$f(x) = x^3 + x^2 - 3x - 3$$

$$f'(x) = 3x^2 + 2x - 3$$

$$f''(x) = 6x + 2$$

$$x_{k+1} = \frac{(x_k^3 + x_k^2 - 3x_k - 3)(3x_k^2 + 2x_k - 3)}{(3x_k^2 + 2x_k - 3)^2 - (x_k^3 + x_k^2 - 3x_k - 3)(6x_k + 2)}$$

注 牛顿下山法

如果在构造迭代法时加入要求: $|f(x_{k+1})| < |f(x_k)|$, 因此考虑引入一因子 λ , 建立迭代法

$$x_{k+1} = x_k - \lambda \frac{f(x_k)}{f'(x_k)}$$

在迭代时, 选择一个 λ , 使得

$$|f(x_{k+1})| < |f(x_k)|$$

这种方法称为 Newton 下山法, λ 称为下山因子。 λ 的选取方式按 $\lambda = 1, \frac{1}{2}, \frac{1}{2^2}, \frac{1}{2^3}, \dots$ 的顺序, 直到 $|f(x_{k+1})| < |f(x_k)|$ 成立为止。

6.5 非线性方程组的解法

$$\begin{cases} f_1(x_1, x_2, \dots, x_n) = 0 \\ \dots \\ f_n(x_1, x_2, \dots, x_n) = 0 \end{cases}, \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{pmatrix}, \mathbf{F}(\mathbf{x}) = \begin{pmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \dots f_n(\mathbf{x}) \end{pmatrix}$$

向量值函数 $F: D \subset \mathbb{R}^n \rightarrow \mathbb{R}^n$, $\mathbf{F}(\mathbf{x}^*) = 0$, $\mathbf{x}^* \in D$

例 6.5 判断下列说法是否正确, 正确请填 “T”, 错误请填 “F” ★★★★★☆☆

- 非线性方程组的解通常不唯一. [T]
- 二分法可以推广到多维方程组的求解. [F]

给定向量值函数 $F: D \subset \mathbb{R}^n \rightarrow \mathbb{R}^n$, 求 $x^* \in D$, 使得

$$F(x^*) = 0$$

迭代求解需要讨论的几个问题

- 迭代序列的适定性;
- 迭代序列的收敛性;
- 迭代序列的收敛速度与效率。

例 6.6 判断下列说法是否正确, 正确请填 “T”, 错误请, 填 “F”

对于求解非线性方程组的不动点迭代 $x^{k+1} = G(x^k)$, 若 x^* 为不动点且 $\rho(G'(x^k)) < 1$, 则对任意初值 x^0 , 迭代序列均收敛. [F]

注 Newton 法及其变形

$$\begin{aligned} F: D \subset \mathbb{R}^n \rightarrow \mathbb{R}^n, \quad F(x) = 0 \\ F(x) \approx F(x^k) + F'(x^k)(x - x^k) = 0 \\ x^{k+1} = x^k - [F'(x^k)]^{-1}F(x^k) \quad (k = 0, 1, \dots) \end{aligned}$$

Newton 迭代法

$$\begin{cases} x^{k+1} = x^k + \Delta x^k \\ F'(x^k)\Delta x^k = -F(x^k) \quad (k = 0, 1, \dots) \end{cases}$$

例 6.7 判断下列说法是否正确, 正确请填 “T”, 错误请填 “F”. ★★★★★

Newton 迭代法是不动点迭代的一个特例. [T]

注 简化的 Newton 迭代法 (Simplified Newton iterative method)

$$x^{k+1} = x^k - BF(x^k) \quad (k = 0, 1, \dots), \quad B = [F'(x^0)]^{-1}$$

例 6.8 判断下列说法是否正确, 正确请填 “T”, 错误请填 “F” ★★★★★

简化 Newton 迭代法是不动点迭代的一个特例 [T]

例 6.9 练习 ★★★★★

1. 设权函数 $\rho(x) = 1 + x^2$, 区间为 $[-1, 1]$, 试求首项系数为 1 的正交多项式 $\varphi_n(x)$, $n = 0, 1, 2, 3$.

解

$$\varphi_0(x) = 1$$

$$\begin{aligned}
\varphi_1(x) &= x - \frac{(x, 1)}{(1, 1)} \cdot 1 \\
&= x - \frac{\int_{-1}^1 (1+x^2)x \cdot 1 dx}{\int_{-1}^1 (1+x^2)1 \cdot 1 dx} \cdot 1 = x \\
\varphi_2(x) &= x^2 - \frac{(x^2, 1)}{(1, 1)} \cdot 1 - \frac{(x^2, x)}{(x, x)} \cdot x \\
&= x^2 - \frac{\int_{-1}^1 (1+x^2)x^2 \cdot 1 dx}{\int_{-1}^1 (1+x^2)1 \cdot 1 dx} \cdot 1 - \frac{\int_{-1}^1 (1+x^2)x^2 \cdot x dx}{\int_{-1}^1 (1+x^2)x \cdot x dx} \cdot x \\
&= x^2 - \frac{2}{5} \\
\varphi_3(x) &= x^3 - \frac{(x^3, 1)}{(1, 1)} \cdot 1 - \frac{(x^3, x)}{(x, x)} \cdot x - \frac{(x^3, x^2)}{(x^2, x^2)} \cdot x \\
&= x^3 - \frac{\int_{-1}^1 (1+x^2)x^3 \cdot 1 dx}{\int_{-1}^1 (1+x^2)1 \cdot 1 dx} \cdot 1 - \frac{\int_{-1}^1 (1+x^2)x^3 \cdot x dx}{\int_{-1}^1 (1+x^2)x \cdot x dx} \cdot x - \frac{\int_{-1}^1 (1+x^2)x^3 \cdot x^2 dx}{\int_{-1}^1 (1+x^2)x^2 \cdot x^2 dx} \cdot x^2 \\
&= x^3 - \frac{9}{14}x
\end{aligned}$$

2. $\mathbf{A} \in \mathbb{R}^{n \times n}$ 为对称正定阵, 经一步顺序 Gauss 消元后 \mathbf{A} 约化为 $\begin{bmatrix} a_{11} & \mathbf{a}_1^T \\ 0 & \mathbf{A}_2 \end{bmatrix}$, 证明

\mathbf{A}_2 也是对称正定阵

证明. 可以设 \mathbf{A} 为

$$\mathbf{A} = \begin{bmatrix} a_{11} & \mathbf{a}_1^T \\ \mathbf{a}_1 & \mathbf{A}'_2 \end{bmatrix}$$

其中 \mathbf{A}'_2 为对称正定阵。

根据 Gauss 消元的性质, 得到

$$\mathbf{A}_2 = \mathbf{A}'_2 - \frac{1}{a_{11}} \begin{bmatrix} a_{21}\mathbf{a}_1^T \\ a_{31}\mathbf{a}_1^T \\ \vdots \\ a_{n1}\mathbf{a}_1^T \end{bmatrix}$$

所以, 有

$$\begin{aligned}
\mathbf{A}_2^T &= \mathbf{A}_2'^T - \frac{1}{a_{11}} \begin{bmatrix} a_{21}\mathbf{a}_1 & a_{31}\mathbf{a}_1 \cdots & a_{n1}\mathbf{a}_1 \end{bmatrix} \\
&= \mathbf{A}'_2 - \frac{1}{a_{11}} \begin{bmatrix} a_{21}\mathbf{a}_1^T \\ a_{31}\mathbf{a}_1^T \\ \vdots \\ a_{n1}\mathbf{a}_1^T \end{bmatrix}
\end{aligned}$$

3. $G(x) = \frac{1}{3}x + 3$, 证明 G 在 $[0, 1]$ 上是压缩的, 但没有不动点

证明. 因为 $|G'(x)| = \frac{1}{3} < 1$, 故而 G 在 $[0, 1]$ 上是压缩的.

接下来证明没有不动点, 令 $G(x) = x$, 解得 $x = -\frac{9}{2} \notin [0, 1]$.

综上所述, $G(x) = \frac{1}{3}x + 3$, 证明 G 在 $[0, 1]$ 上是压缩的, 但没有不动点. 证毕!

7 解线性方程组的直接法

定义 7.1 (特征值和谱半径) 设 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$, 若存在一个数 λ (实数或复数) 和非零向量 $x = (x_1, \dots, x_n)^T \in \mathbb{R}^n$, 使

$$Ax = \lambda x$$

则称 λ 为 A 的特征值, x 为 A 对应 λ 的特征向量, A 的全体特征值称为 A 的谱, 记作 $\sigma(A)$, 即 $\sigma(A) = \{\lambda_1, \dots, \lambda_n\}$,

$$\rho(A) = \max_{\lambda \in \sigma(A)} |\lambda|$$

称为 A 的谱半径.

定义 7.2 设 $u, v \in \mathbb{R}^n, \sigma$ 为实数, 则

$$E(u, v, \sigma) = I - \sigma uv^T$$

称为初等矩阵.

初等矩阵 = 单位矩阵 减去 秩最多为 1 的方阵

注 记 $u = (u_1, u_2, \dots, u_n)^T, v = (v_1, v_2, \dots, v_n)^T$ 则

$$E(u, v, \sigma) = (\delta_{ij} - \sigma u_i v_j)_{n \times n}$$

1. 初等矩阵的逆矩阵

$$E^{-1}(u, v, \sigma) = I - \beta uv^T$$

其中 $\beta = \frac{\sigma}{\sigma v^T u - 1}$

2. 其行列式

$$\det(E(u, v, \sigma)) = 1 - \sigma v^T u$$

定义 7.3 (初等-k 下三角矩阵 (或 Gauss 变换)) 设

$$l_k = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ m_{k+1} \\ \vdots \\ m_n \end{pmatrix}, \quad e_k = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

称矩阵 $L_k(l_k) = E(l_k, e_k, 1) = I - l_k e_k^T$ 的初等-k 下三角矩阵 (或 Gauss 变换)

$$L_k(l_k) = E(l_k, e_k, 1) = I - l_k e_k^T$$

$$= \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -m_{k+1} & 1 & \\ & & \vdots & & \ddots \\ & & -m_n & & & 1 \end{bmatrix}$$

对其逆矩阵 $\beta = \frac{1}{e^T l - 1} = 1$

定理 7.1 设有向量 $x = (x_1, x_2, \dots, x_n)^T$, 且 $x_k \neq 0$, 则存在唯一的初等下三角矩阵 (指标为 k) $L_k(l_k) = E(l_k, e_k, 1) = I - l_k e_k^T$, 使

$$L_k(l_k)x = \begin{pmatrix} x_1 \\ \vdots \\ x_k \\ 0 \\ \vdots \\ 0 \end{pmatrix} \equiv y$$

其中

$$l_k = (0, \dots, 0, m_{k+1}, m_n)^T$$

$$m_i = \frac{x_i}{x_k}, \quad (i = k+1, \dots, n)$$

定义 7.4 (初等反射矩阵) 设 $w \in \mathbb{R}^n$ 满足 $\|w\|_2^2 = w^T w = 1, \sigma = 2$, 称初等矩阵

$$E(w, w, 2) = I - 2ww^T \equiv H(w)$$

为初等反射矩阵或 Householder 变换。

定理 7.2 设 $H(w) = I - 2ww^T$ 为初等反设矩阵, 则

1. $H(w)^T = H(w)$ (对称)
2. $H(w)^T = H(w)^{-1}$ (正交)
3. 设 A 为对称阵, 那么


$$A_1 = H^{-1}AH = HAH$$

也是对称的

注 初等反设矩阵的几何意义

$$H(w) = I - 2ww^T, \quad \|w\|_2^2 = w^T w = 1,$$

v' 为 v 关于平面 S 的镜面反设



7.1 Gauss 消元法

得到等价的线性代数方程组

$$\begin{cases}
 a_{11}^{(1)}x_1 + a_{12}^{(1)}x_2 + \cdots + a_{1n}^{(1)}x_n = b_1^{(1)} \\
 a_{ii}^{(i)}x_i + a_{i,i+1}^{(i)}x_{i+1} + \cdots + a_{in}^{(i)}x_n = b_i^{(i)} \\
 \vdots \\
 a_{n-1,n-1}^{(n-1)}x_{n-1} + a_{n-1,n}^{(n-1)}x_n = b_{n-1}^{(n-1)} \\
 a_{nn}^{(n)}x_n = b_n^{(n)}
 \end{cases}$$

算法 7.1: Gauss 消元法

输入: $[A|b]$

输出: x

```

1  $Z = [A|b]$ 
2 for  $k = 1 \rightarrow n - 1$  do
3   for  $i = k + 1 \rightarrow n$  do
4      $Z[i, :] \leftarrow Z[i, :] - \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}} Z[k, :]$ 
5   end
6 end
7  $A = Z[:, 1:n]$ 
8  $b = Z[:, n+1]$ 
9 for  $i = n \rightarrow 1$  do
10   $x[i] = b[i]$ 
11   $x[i] = x[i] - A[i, i+1:n]x[i+1:n]$ 
12   $x[i] = x[i]/A[i, i]$ 
13 end
14 return  $x$ 

```

注 高斯消元法的运算量

$$MD = \frac{n^3}{3} - \frac{n}{3} = \frac{n^3}{3} + O(n)$$

例 7.1 用 Gauss 消去法解线性方程组 (用四位有效数字计算)

$$\begin{cases} 0.0001x_1 + 2x_2 = 1 \\ 2x_1 + 3x_2 = 2 \end{cases} \quad \mathbf{x}^* = \begin{pmatrix} 0.25001875 \\ 0.49998750 \end{pmatrix}$$

解 用 Gauss 消去法求解 回代得到 $x_1 = 0.0000, x_2 = 0.5000$

$$[A|b] = \begin{bmatrix} 0.0001 & 2 & 1 \\ 2 & 3 & 2 \end{bmatrix}$$
$$= \begin{bmatrix} 0.0001 & 2 & 1 \\ 0 & -4.000 \times 10^4 & -2.000 \times 10^4 \end{bmatrix}$$
$$\qquad\qquad\qquad \textcolor{blue}{-39997} \qquad\qquad\qquad \textcolor{blue}{-19998}$$

注 问题:

与精确解相比,该结果相当糟糕

原因: 在求行乘数时用了很小的数 0.0001 作除数

例 7.2 将两个方程互换为

$$\begin{cases} 2x_1 + 3x_2 = 2 \\ 0.0001x_1 + 2x_2 = 1 \end{cases}$$

解 再采用 Gauss 消去法求解 回代得到 $x_1 = 0.2500, x_2 = 0.5000$

$$[A|b] = \begin{bmatrix} 2 & 3 \\ 0.0001 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 3 & 2 \\ 0 & 2 & 0.9998 \end{bmatrix} \begin{matrix} 0.99985 \\ 1.99985 \end{matrix}$$

定义 7.5 (列主元 Gauss 消元法) 经过 k 步约化后

$$\mathbf{A} \rightarrow \mathbf{A}^{(k)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & \cdots & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & \cdots & a_{2n}^{(2)} \\ & & \ddots & & \\ & & & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} \\ & & & \vdots & & \\ & & & & a_{mk}^{(k)} & \cdots & a_{mn}^{(k)} \end{bmatrix}$$

在 $\mathbf{A}^{(k)}$ 的第 k 列选主元, $|a_{i_k,k}^{(k)}| = \max_{k \leq i \leq n} |a_{i,k}^{(k)}|$ 。若 $i_k > k$, 则在 $[\mathbf{A}^{(k)} \mid \mathbf{b}^{(k)}]$ 中将 i_k 与 k 行互换, 再按照 Gauss 消元公式求出 $[\mathbf{A}^{(k+1)} \mid \mathbf{b}^{(k+1)}]$ 。重复以上过程直到求出 $[\mathbf{A}^{(n)} \mid \mathbf{b}^{(n)}]$

例 7.3 要将这段顺序 Gauss 消元法的 Matlab 程序改成列主元 Gauss 消元法，需要在 [A] 处添加代码★★★★☆☆

算法 7.2: Gauss 列主元消元法

输入: $[A|b]$

输出: x

```
1  $Z = [A|b]$ 
2 for  $k = 1 \rightarrow n - 1$  do
    // A
3   for  $i = k + 1 \rightarrow n$  do
        // B
4      $Z[i, :] \leftarrow Z[i, :] - \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}} Z[k, :]$ 
5   end
    // C
6 end
7  $A = Z[:, 1:n]$ 
8  $b = Z[:, n+1]$ 
9 for  $i = n \rightarrow 1$  do
    // D
10   $x[i] = b[i]$ 
11   $x[i] = x[i] - A[i, i+1:n]x[i+1:n]$ 
12   $x[i] = x[i]/A[i, i]$ 
13 end
14 return  $x$ 
```

7.2 直接三角分解法

经过以下变换

$$\begin{aligned} L_1(l_1) &= I - l_1 e_1^T \\ l_1 &= \begin{pmatrix} 0 & \frac{a_{21}}{a_{11}} & \frac{a_{31}}{a_{11}} & \frac{a_{41}}{a_{11}} \end{pmatrix}^T \\ L_1(l_1) &= \begin{pmatrix} 1 & & & \\ -\frac{a_{21}^{(1)}}{a_{11}^{(1)}} & 1 & & \\ -\frac{a_{31}^{(1)}}{a_{11}^{(1)}} & & 1 & \\ -\frac{a_{41}^{(1)}}{a_{11}^{(1)}} & & & 1 \end{pmatrix}, \quad [A^{(2)} \quad b^{(2)}] = L_1(l_1) [A^{(1)} \quad b^{(1)}] \end{aligned}$$

$$\mathbf{L}_2(\mathbf{l}_2) = \begin{pmatrix} 1 & & & \\ 0 & 1 & & \\ 0 & -\frac{a_{32}^{(2)}}{a_{22}^{(2)}} & 1 & \\ 0 & -\frac{a_{42}^{(2)}}{a_{22}^{(2)}} & & 1 \end{pmatrix}, [\mathbf{A}^{(3)} \quad \mathbf{b}^{(3)}] = \mathbf{L}_2(\mathbf{l}_2) [\mathbf{A}^{(2)} \quad \mathbf{b}^{(2)}]$$

$$\mathbf{L}' \mathbf{A} = \mathbf{U} \Rightarrow \mathbf{A} = \mathbf{L} \mathbf{U}$$

其中

$$\mathbf{L}' = \mathbf{L}_1(\mathbf{l}_2) \mathbf{L}_2(\mathbf{l}_1) \cdots \mathbf{L}_{n-1}(\mathbf{l}_{n-1}) = \begin{bmatrix} 1 & & & & \\ l_{21} & 1 & & & \\ \vdots & l_{32} & \ddots & & \\ \vdots & \vdots & & \ddots & \\ l_{n1} & l_{n2} & \cdots & \cdots & 1 \end{bmatrix}$$

定理 7.3 设 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 非奇异, 且各阶顺序主子式

$$D_k = \det \mathbf{A}_k = \begin{vmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & & \vdots \\ a_{k1} & \cdots & a_{kk} \end{vmatrix} \neq 0$$

则 \mathbf{A} 可唯一地分解为一个单位下三角阵 \mathbf{L} 与一个上三角阵 \mathbf{U} 的乘积, 即

$$\mathbf{A} = \mathbf{L} \mathbf{U}$$

例 7.4 请将下列矩阵进行三角分解★★★★☆☆

$$\mathbf{A} = \begin{bmatrix} 2 & -1 & 3 \\ 4 & 2 & 5 \\ 1 & 2 & 0 \end{bmatrix}$$

解

第一行 \mathbf{L}

1	0	0
	1	0
		1

 \mathbf{U}

2	-1	3
0		
0	0	

第一列 \mathbf{L}

1	0	0
2	1	0
$\frac{1}{2}$		1

 \mathbf{U}

2	-1	3
0		
0	0	

第二行 L

1	0	0
2	1	0
$\frac{1}{2}$		1

U

2	-1	3
0	4	-1
0	0	

第二列 L

1	0	0
2	1	0
$\frac{1}{2}$	$\frac{5}{8}$	1

U

2	-1	3
0	4	-1
0	0	

第三行 L

1	0	0
2	1	0
$\frac{1}{2}$	$\frac{5}{8}$	1

U

2	-1	3
0	4	-1
0	0	$-\frac{7}{8}$

例 7.5 用 Doolittle 分解法求解线性方程组★★★★☆

$$\begin{bmatrix} 2 & 1 & 1 \\ 1 & 3 & 2 \\ 1 & 2 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 6 \\ 5 \end{bmatrix}$$

解

$$L = \begin{bmatrix} 1 & & \\ 1/2 & 1 & \\ 1/2 & 3/5 & 1 \end{bmatrix}, U = \begin{bmatrix} 2 & 1 & 1 \\ & 5/2 & 3/2 \\ & & 3/5 \end{bmatrix}$$

求解 $Ly = b$ 得 $y = (4, 4, 3/5)^T$

求解 $Ux = y$ 得 $x = (1, 1, 1)^T$

定义 7.6 若 $A \in \mathbb{R}^{n \times n}$ 对称正定, 则存在唯一的对角元为正的下三角矩阵 L , 使 A 分解为

$$A = LL^T$$

例 7.6 用平方根法求解线性方程组★★★★☆

$$\begin{pmatrix} 4 & -1 & 1 \\ -1 & 4.25 & 2.75 \\ 1 & 2.75 & 3.5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 6 \\ -0.5 \\ 1.25 \end{pmatrix}$$

则分解后矩阵中的 $l_{21} = [-0.5]$ 。

7.3 大型带状方程组的求解

定义 7.7 (三对角方程) 方程组 $A\mathbf{x} = \mathbf{f}$ 称为三对角方程

其中

$$A = \begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & \ddots & \\ & & \ddots & \ddots & c_{n-1} \\ & & & a_n & b_n \end{bmatrix}, \quad \mathbf{f} = \begin{bmatrix} f_1 \\ f_2 \\ f_3 \\ \vdots \\ f_n \end{bmatrix}.$$

$$A = \begin{pmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & a_n & b_n \end{pmatrix}$$

$$= \begin{pmatrix} \alpha_1 & \alpha_1\beta_1 & & & \\ \gamma_2 & \gamma_2\beta_1 + \alpha_2 & \alpha_2\beta_2 & & \\ & \gamma_3 & \ddots & \ddots & \\ & & \ddots & \gamma_{n-1}\beta_{n-2} + \alpha_{n-1} & \alpha_{n-1}\beta_{n-1} \\ & & & \gamma_n & \gamma_n\beta_{n-1} + \alpha_n \end{pmatrix}$$

7.4 向量和矩阵范数

定义 7.8 设 $\mathbf{x} \in \mathbb{R}^n$ (或 $\mathbf{x} \in \mathbb{C}^n$), 关于 \mathbf{x} 的某个实值非负函数 $N(\mathbf{x}) \equiv \|\mathbf{x}\|$, 如果满足下列条件:

1. $\|\mathbf{x}\| \geq 0$, 且 $\|\mathbf{x}\| = 0 \Leftrightarrow \mathbf{x} = \mathbf{0}$
2. $\|\alpha\mathbf{x}\| = |\alpha| \cdot \|\mathbf{x}\|, \alpha \in \mathbb{R}(\mathbb{C});$
3. $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|, \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n(\mathbb{C}^n).$

则称 $N(\mathbf{x}) \equiv \|\mathbf{x}\|$ 是 \mathbb{R}^n (或 \mathbb{C}^n) 上的一个向量范数 (或模)。

注 常用的向量范数

有 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$

- ∞ 范数 $\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$
- 1-范数 $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$

- 2-范数 $\|\mathbf{x}\|_2 = \sum_{i=1}^n (x_i^2)^{1/2}$

定义 7.9 (向量的 w 范数) 向量的 w 范数由矩阵 \mathbf{w} 诱导

1. 设 $N(\mathbf{x}) = \|\mathbf{x}\|_v$ 是 \mathbb{R}^n 上的一个向量范数
2. 设 $\mathbf{w} \in \mathbb{R}^{n \times n}$ 为非奇异矩阵, 则 $M(\mathbf{x}) \equiv \|\mathbf{x}\|_w \equiv \|\mathbf{w}\mathbf{x}\|_v$ 是 \mathbb{R}^n 上的一个向量范数

定义 7.10 (矩阵范数) 关于矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 的某个实值非负函数 $N(\mathbf{A}) \equiv \|\mathbf{A}\|$, 如果满足下列条件:

1. $\|\mathbf{A}\| \geq 0$, 且 $\|\mathbf{A}\| = 0 \Leftrightarrow \mathbf{A} = \mathbf{0}$;
2. $\|\alpha\mathbf{A}\| = |\alpha| \cdot \|\mathbf{A}\|, \alpha \in \mathbb{R}$;
3. $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|, \forall \mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$;
4. $\|\mathbf{AB}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{B}\|, \forall \mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$.

则称 $N(\mathbf{A})$ 是 $\mathbb{R}^{n \times n}$ 上的一个矩阵范数 (或模)。

定义 7.11 (矩阵的 F 范数) $F(\mathbf{A}) \equiv \|\mathbf{A}\|_F = \left(\sum_{i,j=1}^n a_{ij}^2 \right)^{1/2}$

定义 7.12 (矩阵的算子范数) 设 $\mathbf{x} \in \mathbb{R}^n, \mathbf{A} \in \mathbb{R}^{n \times n}$, 已经给出了一种向量范数 $\|\mathbf{x}\|_v$ 定义一个矩阵的非负函数

$$N(\mathbf{A}) \equiv \|\mathbf{A}\|_v = \max_{\substack{\mathbf{x} \in \mathbb{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{Ax}\|_v}{\|\mathbf{x}\|_v} = \max_{\substack{\mathbf{y} \in \mathbb{R}^n \\ \|\mathbf{y}\|=1}} \|\mathbf{Ay}\|_v$$

注 常用的矩阵范数

设 $\mathbf{x} \in \mathbb{R}^n, \mathbf{A} \in \mathbb{R}^{n \times n}$

- $\|\mathbf{A}\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$, 行范数
- $\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$, 列范数
- $\|\mathbf{A}\|_2 = \sqrt{\rho(\mathbf{A}^T \mathbf{A})}$, 2-范数

注 矩阵特征值的界

1. 设 $\mathbf{A} \in \mathbb{R}^{n \times n}$, 则 $\rho(\mathbf{A}) \leq \|\mathbf{A}\|_v, \|\mathbf{A}\|_v$ 为满足相容条件的矩阵范数;
2. 设 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 为对称矩阵, 则 $\|\mathbf{A}\|_2 = \rho(\mathbf{A})$

定理 7.4 设 $\mathbf{A} \in \mathbb{R}^{n \times n}$, 则

$$\lim_{k \rightarrow \infty} \mathbf{A}^k = \mathbf{0} \Leftrightarrow \rho(\mathbf{A}) < 1$$

定理 7.5 设 $\mathbf{B} \in \mathbb{R}^{n \times n}$, 且 $\|\mathbf{B}\| < 1$ ($\|\mathbf{B}\|$ 为矩阵的算子范数), 则 $\mathbf{I} \pm \mathbf{B}$ 为非奇异矩阵, 且有估计

$$\|(\mathbf{I} \pm \mathbf{B})^{-1}\| \leq \frac{1}{1 - \|\mathbf{B}\|}$$

证明. 只证明 $I \pm B$ 为非奇异矩阵, 设 $I - B$ 为奇异矩阵, 则存在非零向量 x 使得

$$(I + B)x = 0$$

那么有

$$\begin{aligned}\|(I + B)x\| &= \|x + Bx\| \leq \|x\| + \|Bx\| \\ &\leq \|x\| + \|B\|\|x\| = (1 + \|B\|)\|x\| \\ &< 2\|x\|\end{aligned}$$

7.5 条件数与病态矩阵

例 7.7 已知 $A = \begin{pmatrix} 1 & -3 \\ -1 & 2 \end{pmatrix}$, 求 $\|A\|_\infty, \|A\|_1, \|A\|_2$. ★★★★★☆

解 $\|A\|_\infty = 4, \|A\|_1 = 5$

$$A^T A = \begin{pmatrix} 1 & -1 \\ -3 & 2 \end{pmatrix} \begin{pmatrix} 1 & -3 \\ -1 & 2 \end{pmatrix} = \begin{pmatrix} 2 & -5 \\ -5 & 13 \end{pmatrix}$$

$$\lambda_{1,2} = \frac{15 \pm \sqrt{221}}{2} \quad \|A\|_2 = \sqrt{\frac{15 + \sqrt{221}}{2}} \approx 3.864$$

注 常用条件数:

$$\text{Cond}(A)_\infty = \|A^{-1}\|_\infty \cdot \|A\|_\infty$$

$$\begin{aligned}\text{Cond}(A)_2 &= \|A^{-1}\|_2 \cdot \|A\|_2 \\ &= \sqrt{\lambda_{\max}(A^T A)^{-1}} \cdot \sqrt{\lambda_{\max}(A^T A)} = \frac{\sqrt{\lambda_{\max}(A^T A)}}{\sqrt{\lambda_{\min}(A^T A)}}\end{aligned}$$

A 非奇异、对称, $\|\lambda_1\| \geq \|\lambda_2\| \geq \cdots \geq \|\lambda_n\|$

$$\text{Cond}(A)_2 = \frac{\|\lambda_1\|}{\|\lambda_n\|}$$

例 7.8 $A = \begin{bmatrix} 1. & 1. \\ 1. & 1.0001 \end{bmatrix}$ 的条件数 $\text{Cond}(A)_\infty = [40000]$

解

$$A = \begin{bmatrix} 1. & 1. \\ 1. & 1.0001 \end{bmatrix}$$

$$\mathbf{A}^{-1} = \begin{bmatrix} 1.0001 & -1. \\ -1. & 1. \end{bmatrix} \cdot \frac{1}{0.0001}$$

$$\|\mathbf{A}\|_{\infty} = 2.0001 \quad \|\mathbf{A}^{-1}\|_{\infty} = 2.0001 \times 10^4$$

$$\text{Cond}(\mathbf{A})_{\infty} \approx 4. \times 10^4$$

注 如何判断 $\mathbf{Ax} = \mathbf{b}$ 是病态?

1. 估计条件数;
2. 若用列主元消去法求解方程组 $\mathbf{Ax} = \mathbf{b}$, 在约化中出现小主元, 可能是病态;
3. $\mathbf{Ax} = \mathbf{b}$ 出现一个相对很大的解, 可能是病态;
4. \mathbf{A} 中的元素的数量级相差很大, 可能是病态;
5. 当 $\det(\mathbf{A})$ 相对很小、或 \mathbf{A} 某些行 (列) 近似线性相关, 可能是病态

8 解线性方程组的迭代法

8.1 迭代法的构造

注 迭代法的基本思想:

$$\mathbf{Ax} = \mathbf{b} \Leftrightarrow \mathbf{x} = \mathbf{Bx} + \mathbf{f}$$

选取初始向量 $\mathbf{x}^{(0)}$, 构造迭代格式:

$$\begin{aligned} \mathbf{x}^{(1)} &= \mathbf{Bx}^{(0)} + \mathbf{f} \\ \mathbf{x}^{(2)} &= \mathbf{Bx}^{(1)} + \mathbf{f} \\ &\vdots \\ \mathbf{x}^{(k)} &= \mathbf{Bx}^{(k-1)} + \mathbf{f} \end{aligned}$$

两边取极限得到

$$\mathbf{x}^* = \mathbf{Bx}^* + \mathbf{f}$$

注 迭代法构造的一般原则:

将系数矩阵分解为

$$\mathbf{A} = \mathbf{M} - \mathbf{N}$$

故而有

$$\mathbf{Ax} = \mathbf{b} \Leftrightarrow \mathbf{Mx} = \mathbf{Nx} + \mathbf{b}$$

从而方程组等价化为

$$\mathbf{x} = \mathbf{M}^{-1}\mathbf{Nx} + \mathbf{M}^{-1}\mathbf{b}$$

需要满足以下条件

- M 非奇异
- M^{-1} 容易求

迭代法的收敛性

定理 8.1 (迭代法基本定理) 对于任意的初始向量 $\mathbf{x}^{(0)}$, 迭代法构

$$\mathbf{x}^{(k)} = B\mathbf{x}^{(k-1)} + \mathbf{f}$$

收敛的充分必要条件为

$$|\lambda_i(B)| < 1, \quad (i = 1, \dots, n)$$

或者

$$\rho(B) < 1$$

例 8.1 用迭代法求解下列方程组

$$\begin{cases} 8x_1 - 3x_2 + 2x_3 = 20 \\ 4x_1 + 11x_2 - x_3 = 33 \\ 6x_1 + 3x_2 + 12x_3 = 36 \end{cases} \quad \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 3.0000 \\ 2.0000 \\ 1.0000 \end{pmatrix}$$

解 将系数矩阵分解为

$$\begin{pmatrix} 8 & -3 & 2 \\ 4 & 11 & -1 \\ 6 & 3 & 12 \end{pmatrix} = \begin{pmatrix} 8 & & \\ & 11 & \\ & & 12 \end{pmatrix} - \begin{pmatrix} 0 & 3 & -2 \\ -4 & 0 & 1 \\ -6 & -3 & 0 \end{pmatrix}$$

从而构造迭代法

$$\mathbf{x}^k = M^{-1}N\mathbf{x}^{(k-1)} + M^{-1}\mathbf{b}$$

定理 8.2 对于任意的初始向量 $\mathbf{x}^{(0)}$, 若存在 B 的某种范数 $\|\cdot\|$, 使得 $\|B\| = q < 1$, 则迭代法收敛, 且

1. $\|\mathbf{x}^{(k)} - \mathbf{x}^*\| \leq \frac{q}{1-q} \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|$;
2. $\|\mathbf{x}^{(k)} - \mathbf{x}^*\| \leq \frac{q^k}{1-q} \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|$.

证明. 先证明 1

$$\begin{aligned} \|\mathbf{x}^{(k)} - \mathbf{x}^*\| &= \|B(\mathbf{x}^{(k-1)} - \mathbf{x}^*)\| \\ &\leq \|B\| \|\mathbf{x}^{(k-1)} - \mathbf{x}^*\| \\ &= \|B\| \|(\mathbf{x}^{(k-1)} - \mathbf{x}^{(k)}) + (\mathbf{x}^{(k)} - \mathbf{x}^*)\| \\ &\leq \|B\| \|(\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)})\| + \|B\| \|(\mathbf{x}^{(k)} - \mathbf{x}^*)\| \\ &= q \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\| + q \|\mathbf{x}^{(k)} - \mathbf{x}^*\| \end{aligned}$$

故而

$$\| \mathbf{x}^{(k)} - \mathbf{x}^* \| \leq \frac{q}{1-q} \| \mathbf{x}^{(k)} - \mathbf{x}^{(k-1)} \|$$

再证明 2

$$\begin{aligned} \| \mathbf{x}^{(k)} - \mathbf{x}^* \| &\leq \frac{q}{1-q} \| \mathbf{x}^{(k)} - \mathbf{x}^{(k-1)} \| \\ &\leq \frac{q^k}{1-q} \| \mathbf{x}^{(1)} - \mathbf{x}^{(0)} \| \end{aligned}$$

例 8.2 对线性方程组

$$\begin{pmatrix} 3 & 2 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 3 \\ -1 \end{pmatrix}$$

若用迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha(\mathbf{A}\mathbf{x}^{(k)} - \mathbf{b})$$

求解, 则 $\alpha \in [(-0.5, 0)]$ 时迭代收敛, $\alpha = [-0.4]$ 时迭代收敛最快。


解 由 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha(\mathbf{A}\mathbf{x}^{(k)} - \mathbf{b})$ 知道

$$\mathbf{x}^{(k+1)} = (\alpha\mathbf{A} + \mathbf{I})\mathbf{x}^{(k)} - \alpha\mathbf{b}$$

求 $\alpha\mathbf{A} + \mathbf{I}$ 的谱半径 ρ

$$\begin{aligned} &\begin{vmatrix} \lambda - 3\alpha - 1 & -2\alpha \\ -\alpha & \lambda - 2\alpha - 1 \end{vmatrix} \\ &= \lambda^2 - (5\alpha + 2)\lambda + (3\alpha + 1)(2\alpha + 1) - 2\alpha^2 \\ &= \lambda^2 - (5\alpha + 2)\lambda + 4\alpha^2 + 5\alpha + 1 \\ &= [\lambda - (4\alpha + 1)][\lambda - (\alpha + 1)] \end{aligned}$$

谱半径的图像 $\rho = \max \{ |4\alpha + 1|, |\alpha + 1| \}$



当 $\alpha \in (-0.5, 0)$ 时迭代收敛, $\alpha = -0.4$ 时迭代收敛最快

8.1.1 Jacobi 迭代法

设 $a_{ii} \neq 0, (i = 1, 2, \dots, n)$, $M = D, N = D - A$, 有

$$\begin{aligned} B_J &= D^{-1}(D - A) = I - D^{-1}A = D^{-1}(L + U) \\ f &= D^{-1}b \end{aligned}$$

$$\mathbf{x}^{(k+1)} = B_J \mathbf{x}^{(k)} + \mathbf{f}$$

定理 8.3 (Jacobi 迭代的收敛性定理) Jacobi 迭代法收敛有以下结论

- Jacobi 迭代法收敛的充分必要条件是

$$\rho(B_J) < 1$$

- Jacobi 迭代法收敛的充分条件是存在一种范数 $\|\cdot\|$, 使得 $\|B_J\| \leq 1$

8.1.2 Gauss-Seidel 迭代法

$$\begin{aligned} x_1^{(k+1)} &= \frac{1}{a_{11}}(b_1 - \sum_{j=2}^n a_{1j}x_j^{(k)}) \\ x_2^{(k+1)} &= \frac{1}{a_{22}}(b_2 - a_{21}x_1^{(k+1)} - \sum_{j=3}^n a_{2j}x_j^{(k)}) \\ &\dots\dots\dots \\ x_i^{(k+1)} &= \frac{1}{a_{ii}}(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)}) \\ \mathbf{x}^{(k+1)} &= \mathbf{G}\mathbf{x}^{(k)} + \mathbf{f}_G \end{aligned}$$

其中

$$\mathbf{G} = (D - L)^{-1}U, \mathbf{f}_G = (D - L)^{-1}\mathbf{b}$$

定理 8.4 (GS 迭代的收敛性定理) GS 迭代法收敛的充分必要条件是

- GS 迭代法收敛的充分必要条件是

$$\rho(\mathbf{G}) < 1$$

- GS 迭代法收敛的充分条件是存在一种范数 $\|\cdot\|$, 使得 $\|\mathbf{G}\| \leq 1$

8.1.3 SOR

$$\begin{aligned}
 \tilde{x}_i^{(k+1)} &= \frac{1}{a_{ii}}(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)}) \\
 x_i^{(k+1)} &= (1-\omega)x_i^{(k)} + \omega\tilde{x}_i^{(k+1)} \\
 &= x_i^{(k)} + \omega(\tilde{x}_i^{(k+1)} - x_i^{(k)}) \\
 &= (1-\omega)x_i^{(k)} + \frac{\omega}{a_{ii}}(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)})
 \end{aligned}$$

其中 ω 为可选择的松弛因子

$$\begin{aligned}
 \mathbf{x}^{(k+1)} &= (1-\omega)\mathbf{x}^{(k)} + \omega\mathbf{D}^{-1}(\mathbf{b} + \mathbf{L}\mathbf{x}^{(k+1)} + \mathbf{U}\mathbf{x}^{(k)}) \\
 (\mathbf{D} - \omega\mathbf{L})\mathbf{x}^{(k+1)} &= [(1-\omega)\mathbf{D} + \omega\mathbf{U}]\mathbf{x}^{(k)} + \omega\mathbf{b}
 \end{aligned}$$

表示为矩阵

$$\begin{aligned}
 \mathbf{x}^{(k+1)} &= \mathbf{G}_\omega \mathbf{x}^{(k)} + \mathbf{f}_\omega \\
 \mathbf{G}_\omega &= (\mathbf{D} - \omega\mathbf{L})^{-1}[(1-\omega)\mathbf{D} + \omega\mathbf{U}] \\
 \mathbf{f}_\omega &= \omega(\mathbf{D} - \omega\mathbf{L})^{-1}\mathbf{b}
 \end{aligned}$$

定理 8.5 ((SOR 方法收敛的必要条件)) 设解 $\mathbf{Ax} = \mathbf{b}$ ($\mathbf{A} \in \mathbb{R}^{n \times n}$) 的 SOR 方法收敛。则 $0 < \omega < 2$ 。

证明. SOR 法收敛就是 $\rho(\mathbf{G}_\omega) < 1$ 因为 $\mathbf{G}_\omega = (\mathbf{D} - \omega\mathbf{L})^{-1}[(1-\omega)\mathbf{D} + \omega\mathbf{U}]$

$$\begin{aligned}
 |\det(\mathbf{D} - \omega\mathbf{L})| &= \prod_{i=1}^n |a_{ii}| \\
 |\det((1-\omega)\mathbf{D} + \omega\mathbf{U})| &= |(1-\omega)^n| \prod_{i=1}^n |a_{ii}| \\
 |\det(\mathbf{G}_\omega)| &= |(1-\omega)^n| \leq \rho(\mathbf{G}_\omega)^n \\
 |(1-\omega)| &< \rho(\mathbf{G}_\omega) < 1 \\
 -1 &< 1-\omega < 1 \\
 0 &< \omega < 2
 \end{aligned}$$

证毕！

注 关于解特殊方程组迭代法的收敛性

定义 8.1 (对角占优) 设 $\mathbf{A} = (a_{ij}) \in \mathbb{R}^{n \times n}$, 则

- 若 $|a_{ii}| > \sum_{j=1}^n |a_{ij}|$ ($i = 1, 2, \dots, n$), 称 \mathbf{A} 为严格对角占优矩阵 (或强占优阵)。

- 若 $|a_{ii}| \geq \sum_{j=1}^n |a_{ij}|$ ($j = 1, 2, \dots, n$), 且至少有一个不等式严格成立, 则称 A 为弱对角占优阵。

定义 8.2 ((可约与不可约阵)) 设 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$ ($n \geq 2$), 如果存在置换矩阵 P 使

$$P^T A P = \begin{pmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{pmatrix}$$

其中 A_{11} 为 r 阶方阵, A_{22} 为 $n-r$ 阶方阵 ($1 \leq r < n$), 则称 A 为可约矩阵; 否则如果不存在这样的置换矩阵 P 使上式成立, 称 A 为不可约阵。

$$Ax = b \Rightarrow P^T A P P^T x = P^T b$$

$$\begin{pmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \begin{pmatrix} C_1 \\ C_2 \end{pmatrix}$$

定理 8.6 设 $Ax = b, A = (a_{ij}) \in \mathbb{R}^{n \times n}$,

- 如果 A 为严格对角占优阵, 则解方程组 $Ax = b$ 的 J 法及 GS 法均收敛。
- 如果 A 为弱对角占优阵且不可约阵, 则解方程组 $Ax = b$ 的 J 法及 GS 法均收敛。

定理 8.7 设 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$, 若

1. A 严格对角占优或弱对角占优且不可约,
2. $0 < \omega \leq 1$,

则解方程组 $Ax = b$ 的 SOR 法收敛。

定理 8.8 设 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$, 若

1. A 为对称正定矩阵,
2. $0 < \omega < 2$,

则解方程组 $Ax = b$ 的 SOR 法收敛。

注 迭代法的收敛速度

$$\text{记 } \epsilon^{(k)} = x^{(k)} - x^*,$$

$$x^{(k+1)} = Bx^{(k)} + f$$

$$x^{(*)} = Bx^{(*)} + f$$

$$\epsilon^{(k+1)} = B\epsilon^{(k)} = \dots = B^{k+1}\epsilon^{(0)}$$

则有 $\epsilon^{(k)} = B^k \epsilon^{(0)}$

若迭代 k 步后, 有 $\|\epsilon^{(k)}\| \leq 10^{-m} \|\epsilon^{(0)}\|$

误差模的缩减因子接近 $[\rho(\mathbf{B})]^k$

$$[\rho(\mathbf{B})]^k \leq 10^{-m}$$

称

$$R(\mathbf{B}) = -\ln \rho(\mathbf{B})$$

为迭代法的渐近收敛速度。

8.2 梯度法

线性方程组 (\mathbf{A} 对称正定):

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

- 经典算法: Gauss 消元法、系数矩阵三角分解法
- 算法缺陷: 计算时间随问题规模急速增长。

将问题转化为

$$\min f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T \mathbf{A}\mathbf{x} - \mathbf{b}^T \mathbf{x}$$

8.3 最速下降法

$$\mathbf{d}_k = -\nabla f(\mathbf{x}_k) = \mathbf{b} - \mathbf{A}\mathbf{x}_k$$

$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}} f(\mathbf{x}_k + \alpha \mathbf{d}_k) = \frac{\langle \mathbf{d}_k, \mathbf{d}_k \rangle}{\langle \mathbf{A}\mathbf{d}_k, \mathbf{d}_k \rangle}$$

8.3.1 共轭方向法

定义 8.3 (共轭方向) 对对称正定阵 \mathbf{A} , 若 $\mathbf{d}_1, \mathbf{d}_2 \in \mathbb{R}^n$, 满足 $\mathbf{d}_1^T \mathbf{A}\mathbf{d}_2 = 0$, 则称 $\mathbf{d}_1, \mathbf{d}_2$ 关于矩阵 \mathbf{A} 共轭, 并称其为 \mathbf{A} 的共轭方向。

共轭是正交的推广。

定义 8.4 (线性共轭方向的推广) 若向量组 $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_n$ 关于对称正定阵 \mathbf{A} 两两共轭, 即满足

$$\mathbf{d}_i^T \mathbf{A}\mathbf{d}_j = 0, 1 \leq i \neq j \leq n$$

推论 若向量组 $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_n$, 关于矩阵 \mathbf{A} 共轭, 则它们线性无关。

注 线性共轭方向法:

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T \mathbf{A}\mathbf{x} - \mathbf{b}^T \mathbf{x}$$

1. 初始点 \mathbf{x}_0 , 搜索方向 \mathbf{d}_0 满足 $\langle \mathbf{d}_0, \mathbf{g}_0 \rangle < 0$, 终止参数 $\varepsilon \geq 0$, 令 $k = 0$
2. 若 $\|\mathbf{g}_k\| \leq \varepsilon$, 算法终止; 否则, 进入下一步
3. 计算最优步长 $\alpha = \arg \min_{\alpha \geq 0} \{f(\mathbf{x}_k + \alpha \mathbf{d}_k)\}$, 令 $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$
4. 构造 \mathbf{d}_{k+1} 使其与 $\mathbf{d}_0, \dots, \mathbf{d}_k$ 关于矩阵 \mathbf{A} 共轭, 令 $k \leftarrow k + 1$, 返回步 2

定理 8.9 (二次终止性) 对严格凸二次函数 $\min f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x}$, 向量组 $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$ 关于 \mathbf{A} 共轭。共轭方向发产生点列 $\{\mathbf{x}_k\}$ 。则对任意 $0 \leq k \leq n-1$, \mathbf{x}_{k+1} 是目标函数在仿射集 $\mathbf{x}_0 + \text{span}[\mathbf{d}_0, \dots, \mathbf{d}_k]$ 上的最小值点, 算法至多 n 步迭代后终止。

例 8.3 利用共轭梯度法求 $\mathbf{A} \mathbf{x} = \mathbf{b}$ 或者说, 利用共轭梯度法求 $\min x_1^2 + \frac{1}{2} x_2^2 + \frac{1}{2} x_3^2$

★★★★★

其中,

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & 0 & \frac{1}{2} \end{bmatrix}, \quad \mathbf{b} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

解 取初始点 $\mathbf{x}_0 = (1, 1, 1)^T$, 迭代过程:

1. $\mathbf{x}_0 = (1, 1, 1)^T$, $\mathbf{g}_0 = \mathbf{A} \mathbf{x}_0 - \mathbf{0} = (2, 1, 1)^T$, $\beta_{-1} = 0$, $\mathbf{d}_0 = -\mathbf{g}_0$.

$$\begin{aligned} \alpha &= \arg \min f(\mathbf{x}_0 + \alpha \mathbf{d}_0) \\ &= (1 - 2\alpha)^2 + \frac{1}{2}(1 - \alpha)^2 + \frac{1}{2}(1 - \alpha)^2 = \frac{3}{5} \end{aligned}$$

2. $\mathbf{x}_1 = \mathbf{x}_0 + \alpha_0 \mathbf{d}_0 = \frac{1}{5}(-1, 2, 2)^T$, $\mathbf{g}_1 = \mathbf{A} \mathbf{x}_1 - \mathbf{0} = \frac{1}{5}(-1, 2, 2)^T$, $\beta_0 = \frac{\mathbf{g}_1^T \mathbf{g}_1}{\mathbf{g}_0^T \mathbf{g}_0} = \frac{2}{25}$

$$\mathbf{d}_1 = -\mathbf{g}_1 + \beta_0 \mathbf{g}_0 = -\frac{6}{25}(1, -2, -2)^T$$

$$\begin{aligned} \alpha &= \arg \min f(\mathbf{x}_0 + \alpha \mathbf{d}_0) \\ &= (1 - 2\alpha)^2 + \frac{1}{2}(1 - \alpha)^2 + \frac{1}{2}(1 - \alpha)^2 = \frac{3}{5} \end{aligned}$$

3. $\mathbf{x}_2 = \mathbf{x}_1 + \alpha_1 \mathbf{d}_1 = \mathbf{0}$, $\|\mathbf{g}_2\| = 0$, 终止。

k	\mathbf{x}_k	\mathbf{g}_k	β_{k-1}	\mathbf{d}_k	α_k
0	$(1, 1, 1)^T$	$(2, 1, 1)^T$	0	$-(2, 1, 1)^T$	$\frac{3}{5}$
1	$\frac{1}{5}(-1, 2, 2)^T$	$\frac{1}{5}(-2, 2, 2)^T$	$\frac{2}{25}$	$-\frac{6}{25}(1, -2, -2)^T$	$\frac{5}{6}$
2	$(0, 0, 0)^T$	$(0, 0, 0)^T$			

定理 8.10 (收敛速度) 对严格凸二次函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x}$. 若系数矩阵 \mathbf{A} 有 r 个相异特征根, 则最优步长规则下的共轭梯度法至多 r 步迭代后终止。

9 矩阵的特征值和特征向量的计算

9.1 特征值理论

定理 9.1 (Gerschgorin 圆盘定理) 关于 A 有以下结论

1. 设 $A = (a_{ij})_{n \times n}$, 则 A 的每一个特征值必属于下述某个圆盘; $|\lambda - a_{ii}| \leq r_i = \sum_{j \neq i} |a_{ij}|$ ($j = 1, 2, \dots, n$)
2. 若 A 的 m 圆盘组成并集 S (连通的) 且与余下的 $n - m$ 个圆盘是分离的 (即不相交), 则 S 内恰包含 m 个 A 的特征值。特别, 当 S 是由一个圆盘组成且与其他 $n - 1$ 个圆盘是分离的 (即为孤立圆盘), 则 S 中精确地包含 A 的一个特征值。

证明. 设 $x \neq 0$ 为 A 的特征向量, 那么有

$$Ax = \lambda x$$

取 x 中分量的绝对值最大的一个, 设为 x_i

$$\begin{aligned} (\lambda - a_{ii})x_i &= \sum_{\substack{j=1 \\ j \neq i}} a_{ij}x_j \\ \Rightarrow |\lambda - a_{ii}||x_i| &= \left| \sum_{\substack{j=1 \\ j \neq i}} a_{ij}x_j \right| \\ \Rightarrow |\lambda - a_{ii}| &= \left| \sum_{\substack{j=1 \\ j \neq i}} a_{ij} \right| \left| \frac{x_j}{x_i} \right| < r_i \end{aligned}$$

证毕!

定理 9.2 设 $A \in \mathbb{R}^{n \times n}$ 为对称矩阵, 其特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$, 其对应的特征向量 x_1, x_2, \dots, x_n 组成规范化正交组, 则

1. $\lambda_n \leq \frac{(Ax, x)}{(x, x)} \leq \lambda_1$ ($\forall x \in \mathbb{R}^n, x \neq 0$)
2. $\lambda_1 = \max_{x \in \mathbb{R}^n} R(x)$
3. $\lambda_n = \min_{x \in \mathbb{R}^n} R(x)$

9.2 幂法

9.2.1 幂法

一种计算矩阵主特征值 (按模最大特征值) 及其特征向量的迭代法。设 $\mathbf{A} = (a_{ij}) \in \mathbb{R}^{n \times n}$, 有一组线性无关的特征向量组

$$\mathbf{A}\mathbf{x}_i = \lambda_i \mathbf{x}_i \quad (i = 1, 2, \dots, n)$$

其中 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 线性无关, 且满足: $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$

注 基本思想: 任取初始向量 $\mathbf{v}_0 \in \mathbb{R}^n$ 且 $\mathbf{v}_0 \neq \mathbf{0}$

$$\begin{cases} \mathbf{v}_1 = \mathbf{A}\mathbf{v}_0 \\ \mathbf{v}_2 = \mathbf{A}\mathbf{v}_1 = \mathbf{A}^2\mathbf{v}_0 \\ \vdots \\ \mathbf{v}_{k+1} = \mathbf{A}\mathbf{v}_k = \mathbf{A}^{k+1}\mathbf{v}_0 \\ \vdots \end{cases}$$

设 $\mathbf{v}_0 = \sum_{i=1}^n \alpha_i \mathbf{x}_i$, $\mathbf{v}_k = \mathbf{A}^k \mathbf{v}_0 = \mathbf{A}^k \left(\sum_{i=1}^n \alpha_i \mathbf{x}_i \right) = \sum_{i=1}^n \alpha_i \lambda_i^k \mathbf{x}_i$, 两边同时除以 λ_1^k

$$\frac{\mathbf{v}_k}{\lambda_1^k} = \alpha_1 \mathbf{x}_1 + \sum_{i=2}^n \alpha_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \approx \alpha_1 \mathbf{x}_1$$

有

$$\mathbf{v}_{k+1} \approx \alpha_1 \lambda_1^{k+1} \mathbf{x}_1$$

$$\mathbf{v}_k \approx \alpha_1 \lambda_1^k \mathbf{x}_1$$

$$\lim_{k \rightarrow \infty} \frac{\mathbf{v}_k}{\lambda_1^k} = \alpha_1 \mathbf{x}_1 \quad \lim_{k \rightarrow \infty} \frac{(\mathbf{v}_{k+1})_i}{(\mathbf{v}_k)_i} = \lambda_1$$

9.2.2 改进幂法

设 $\mathbf{u}_0 = \mathbf{v}_0 \neq \mathbf{0} (\alpha_1 \neq 0)$

迭代 $\mathbf{v}_k = \mathbf{A}\mathbf{u}_{k-1}$, $\mu_k = \max(\mathbf{v}_k)$, $k = 1, 2, \dots$

规范化: $\mathbf{u}_k = \mathbf{v}_k / \mu_k$

仍然设 $\mathbf{v}_0 = \sum_{i=1}^n \alpha_i \mathbf{x}_i$, 那么

$$\mathbf{u}_k = \frac{\sum_{i=1}^n \alpha_i \lambda_i^k \mathbf{x}_i}{\max \left(\sum_{i=1}^n \alpha_i \lambda_i^k \mathbf{x}_i \right)} \stackrel{\text{同时除以 } \lambda_1^k}{=} \frac{\alpha_1 \mathbf{x}_1 + \sum_{i=2}^n \alpha_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i}{\max \left(\alpha_1 \mathbf{x}_1 + \sum_{i=2}^n \alpha_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)} = \frac{\mathbf{x}_1}{\max(\mathbf{x}_1)}, \quad k \rightarrow \infty$$

同时

$$\mu_k = \max(\mathbf{v}_k) = \lambda_1$$

迭代序列	规范化序列
$v_1 = \mathbf{A}u_0 = \mathbf{A}v_0$	$u_1 = \frac{\mathbf{A}v_0}{\max(\mathbf{A}v_0)}$
$v_2 = \frac{\mathbf{A}^2 v_0}{\max(\mathbf{A}v_0)}$	$u_2 = \frac{\mathbf{A}^2 v_0}{\max(\mathbf{A}^2 v_0)}$
\dots	\dots
$v_k = \frac{\mathbf{A}^k v_0}{\max(\mathbf{A}^{k-1} v_0)}$	$u_k = \frac{\mathbf{A}^k v_0}{\max(\mathbf{A}^k v_0)}$

定理 9.3 (改进幂法) 设 (1) $A = (a_{ij}) \in \mathbb{R}^{n \times n}$ 有 n 个线性无关的特征向量; (2) 设 A 的特征值满足: $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ 且 $Ax_i = \lambda_i x_i$ ($i = 1, 2, \dots, n$); (3) $\{u_k\}, \{\nu_k\}$ 由改进幂法得到, 则有:

1. $\lim_{k \rightarrow \infty} u_k = \frac{x_1}{\max(x_1)}$
2. $\mu_k = \max(v_k) = \lambda_1$
3. 且收敛速度 $r = \left| \frac{\lambda_2}{\lambda_1} \right|$ 确定。

10 2023 春考试题目

例 10.1 已知 $f(1) = 5, f'(1) = 7, f'(0) = 1$, 试问满足上插值条件的多项式是否适定? 若不适定请说明理由; 若适定, 则求出该多项式并给出误差估计. ★★★★★

解 设插值多项式 $p(x) = a_0 + a_1x + a_2x^2$ 满足题述条件, 那么有

$$\begin{cases} a_0 + a_1 + a_2 = 5 \\ a_1 + 2a_2 = 7 \\ a_1 = 1 \end{cases}$$

解得 $a_0 = 1, a_1 = 1, a_2 = 3$, 方程组有唯一解, 插值多项式适定。

设插值误差为 $R(x)$, 并做 $\varphi(t) = f(t) - p(t) - W(t)$ 满足 $\varphi(x) = 0$, 即

$$W(x) = R(x)$$

因为 $R(x)$ 满足 $R(1) = R'(1) = 0$, 故而设 $W(t) = (mt + n)(t - 1)^2$, 由 $W'(0) = 0$ 可得

$$m(0 - 1)^2 + (m \cdot 0 + n) \cdot 2 \cdot (0 - 1) = 0$$

解得 $m = 2n$

两次利用罗尔定理可得

$$\varphi'''(\xi) = f'''(\xi) - 3!m = 0$$

解得 $m = \frac{f'''(\xi)}{6}$ 。故而

$$R(x) = \frac{f'''(\xi)}{12}(x-1)^2(2x+1)$$

例 10.2 设 $f(x) = 0$ 有单根 x^* , $x = \varphi(x)$ 是 $f(x) = 0$ 的等价方程, 若 $\varphi(x) = x - m(x)f(x)$, 且所有函数都充分光滑。证明: 当 $m(x^*) \neq \frac{1}{f'(x^*)}$ 时, $x_{k+1} = \varphi(x_k)$ 至多是一阶收敛的; 当 $m(x^*) = \frac{1}{f'(x^*)}$ 时, $x_{k+1} = \varphi(x_k)$ 至少是二阶收敛的。★★★★★

证明. 由 x^* 是 $f(x) = 0$ 的单根, 有

$$f(x^*) = 0, f'(x^*) \neq 0$$

由 $\varphi(x) = x - m(x)f(x)$, 有

$$\begin{aligned}\varphi'(x) &= 1 - m'(x)f(x) - m(x)f'(x) \\ \varphi'(x^*) &= 1 - m'(x^*)f(x^*) - m(x^*)f'(x^*) = 1 - m(x^*)f'(x^*)\end{aligned}$$

由迭代阶的定理, 当 $m(x^*) \neq 1/f'(x^*)$ 时, $\varphi'(x^*) = 1 - m(x^*)f'(x^*) \neq 0$. 此时若 $|\varphi'(x^*)| < 1$, 则迭代法 $x_{k+1} = \varphi(x_k)$ 一阶收敛; 若 $|\varphi'(x^*)| \geq 1$, 则迭代法 $x_{k+1} = \varphi(x_k)$ 不收敛; 故迭代法是最多是一阶收敛的。

当 $m(x^*) = 1/f'(x^*)$ 时, $\varphi'(x^*) = 1 - m(x^*)f'(x^*) = 0$. 此时则迭代法 $x_{k+1} = \varphi(x_k)$ 至少是二阶收敛的。

例 10.3 对下列线性代数方程组给出使 Jacobi 迭代法和 Gauss-Seidel 迭代法均收敛的迭代格式, 要求分别写出这两个迭代格式, 并说明迭代法收敛的理由。★★★★★

$$\begin{cases} 2x_1 - x_2 + x_4 = 1 \\ x_1 - x_3 + 5x_4 = 6 \\ x_2 + 4x_3 - x_4 = 8 \\ -x_1 + 3x_2 - x_3 = 3 \end{cases}$$

解

$$[A | b] = \begin{bmatrix} 2 & -1 & 0 & 1 & 1 \\ 1 & 0 & -1 & 5 & 6 \\ 0 & 1 & 4 & -1 & 8 \\ -1 & 3 & -1 & 0 & 3 \end{bmatrix} \xrightarrow[r_1 \times 10 + r_2]{r_2 \leftrightarrow r_4} \begin{bmatrix} 19 & -7 & -1 & 10 & 10 \\ -1 & 3 & -1 & 0 & 3 \\ 0 & 1 & 4 & -1 & 8 \\ 1 & 0 & -1 & 5 & 6 \end{bmatrix}$$

因其变化后为等价方程组, 且严格对角占优, 故而 Jacobi 迭代法和 Gauss-Seidel 迭代法均收敛。

Jacobi 迭代格式为:

$$\begin{cases} x_1^{(m+1)} = \frac{1}{19}(7x_2^{(m)} + x_3^{(m)} - 10x_4^{(m)} + 10) \\ x_2^{(m+1)} = \frac{1}{3}(x_1^{(m)} + x_3^{(m)} + 3) \\ x_3^{(m+1)} = \frac{1}{4}(-x_2^{(m)} + x_4^{(m)} + 8) \\ x_4^{(m+1)} = \frac{1}{5}(-x_1^{(m)} + x_3^{(m)} + 6) \end{cases} \quad (m = 0, 1, 2, \dots)$$

Gauss-Seidel 迭代格式:

$$\begin{cases} x_1^{(m+1)} = \frac{1}{19}(7x_2^{(m)} + x_3^{(m)} - 10x_4^{(m)} + 10) \\ x_2^{(m+1)} = \frac{1}{3}(x_1^{(m+1)} + x_3^{(m)} + 3) \\ x_3^{(m+1)} = \frac{1}{4}(-x_2^{(m+1)} + x_4^{(m)} + 8) \\ x_4^{(m+1)} = \frac{1}{5}(-x_1^{(m+1)} + x_3^{(m+1)} + 6) \end{cases} \quad (m = 0, 1, 2, \dots)$$

例 10.4 求 $f(x) = 3x^3 + 2x^2 + x$ 在区间 $[-1, 1]$ 上的 2 次最佳一致逼近多项式。

★★★★★

解 切比雪夫多项式为

$$\begin{aligned} T_0(x) &= 1 \\ T_1(x) &= x \\ T_2(x) &= 2x^2 - 1 \\ T_3(x) &= 2xT_2(x) - T_1(x) = 4x^3 - 3x \end{aligned}$$

有

$$\begin{aligned} \frac{f(x) - p(x)}{3} &= \frac{T_3(x)}{4} \\ \Rightarrow p(x) &= 2x^2 + \frac{13}{4}x \end{aligned}$$

例 10.5 已知 $f(-1) = 1, f(-0.5) = 4, f(0) = 6, f(0.5) = 9, f(1) = 2$, 且 $|f^{(4)}(x)| \leq M (\forall x \in [-1, 1])$, M 为常数, 试估计用复合 Simpson 公式计算积分 $\int_{-1}^1 f(x)dx$ 的整体截断误差限.★★★★★

解 因为

$$\begin{aligned} \int_{-1}^1 f(x)dx &= \int_{-1}^0 f(x)dx + \int_0^1 f(x)dx \\ &\approx [\frac{1}{6}f(-1) + \frac{4}{6}f(-0.5) + \frac{1}{6}f(0)] + [\frac{1}{6}f(0) + \frac{4}{6}f(0.5) + \frac{1}{6}f(1)] \\ &\approx \frac{1}{6}[1 + 4 \times 4 + 6 + 6 + 4 \times 9 + 2] = \frac{67}{6} \approx 11.1667 \end{aligned}$$

误差

$$\begin{aligned}|I - S_2| &\leq \left| \int_{-1}^0 \frac{f^{(4)}(\xi_1)}{4!} (x+1)(x+0.5)^2(x-0)dx \right| + \left| \int_0^1 \frac{f^{(4)}(\xi_2)}{4!} (x-0)(x-0.5)^2(x-1)dx \right| \\&\leq \frac{M}{24} \left[\int_{-1}^0 |(x+1)(x+0.5)^2(x-0)|dx + \int_0^1 |(x-0)(x-0.5)^2(x-1)|dx \right] \\&\leq \frac{M}{12} \int_0^1 |(x-0)(x-0.5)^2(x-1)|dx = \frac{M}{6} \int_0^{0.5} t^2(0.25-t^2)dt = \frac{M}{6} \times 0.0042 \\&\leq 0.008M\end{aligned}$$

例 10.6 设 n 阶实矩阵 A 的特征值满足: $\lambda_1 = \lambda_2, \lambda_1 > |\lambda_3| \geq \cdots \geq |\lambda_n|$, 试讨论用幂法如何求主特征值, 并分析收敛性.

例 10.7 设多元函数 $G: D \subset \mathbb{R}^n \rightarrow \mathbb{R}^n, \forall \mathbf{x}, \mathbf{y} \in D_0 \subset D$ 都有 $\|G(\mathbf{x}) - G(\mathbf{y})\| \leq \|\mathbf{x} - \mathbf{y}\|$, 则称 G 在 D_0 为非膨胀映射, 若当 $\mathbf{x} \neq \mathbf{y}$ 时不等式严格成立, 则称 G 在 D_0 为严格非膨胀映射.

假定 $G: D \subset \mathbb{R}^n \rightarrow \mathbb{R}^n$, 在有界闭集 $D_0 \subset D$ 上是严格非膨胀映射, 且 $G(D_0) \subset D_0$, 证明 G 在 D_0 中有唯一不动点. ★★★★★

证明. 设 $\varphi(\mathbf{x}) = \|\mathbf{x} - G(\mathbf{x})\|$

显然, 设 $\varphi(\mathbf{x}) = \|\mathbf{x} - G(\mathbf{x})\|$ 在 D_0 上连续, 而 D_0 为闭集, 故 $\varphi(\mathbf{x})$ 在 D_0 上有最小值, 记为 $\varphi(\mathbf{x}^*) = \min_{\mathbf{x} \in D_0} \|\mathbf{x} - G(\mathbf{x})\|$

若 $G(\mathbf{x}^*) \neq \mathbf{x}^*$, 则有

$$\varphi(G(\mathbf{x}^*)) = \|G(\mathbf{x}^*) - G(G(\mathbf{x}^*))\| < \|\mathbf{x}^* - G(\mathbf{x}^*)\|$$

矛盾!

所以必有 $G(\mathbf{x}^*) = \mathbf{x}^*$ 。